Business Intelligence

Proyecto final · Entrega 1

Diagnóstico, estrategia y diseño

Secretaría de Educación del Distrito de Bogotá: ¿la pandemia amplió la brecha entre colegios oficiales y no oficiales en el Saber 11?

Integrante	Código
Laura Valentina López García	506232714
Juan Camilo Prieto Mestizo	506232717
Diego Alejandro Gil Moreno	507232716

Dato	Valor
Docente	Leandro Pájaro Fuentes
Fecha de entrega	23/10/2026
Repositorio	https://github.com/KamiroDark/bi-proyecto-equipo506232717

Resumen de la entrega

La Secretaría de Educación del Distrito (SED) de Bogotá debe decidir a qué colegios oficiales y localidades dirigir sus programas de refuerzo académico. Hoy no puede hacerlo con evidencia porque los resultados del examen Saber 11 (ICFES), el directorio georreferenciado de colegios (SED) y la matrícula de cada establecimiento (Ministerio de Educación Nacional) están en sistemas distintos, con códigos, formatos y fechas de corte que no coinciden. Con esos datos integrados se encontró que la diferencia de puntaje entre colegios no oficiales y oficiales pasó de 24,9 puntos en 2019 a 30,7 en 2022, y que creció en 15 de las 19 localidades urbanas.

Diagnóstico de madurez: la SED se encuentra en la fase 2 del BIMM (Datos accesibles sin BI): los datos son públicos y accesibles, pero se consultan por separado y se consolidan a mano en boletines anuales en PDF. La fase objetivo al final del proyecto es la fase 4 (Data warehouse), con un almacén dimensional integrado, un tablero y un modelo predictivo.

Granularidad del modelo dimensional: una fila de la tabla de hechos representa el resultado de un estudiante en una aplicación del examen Saber 11, presentado en un colegio de Bogotá. La tabla de hechos se alimenta de 361.719 resultados únicos de 2016 a 2022.

1. Caso de negocio

1.1 Organización y contexto

Nota: el escenario se plantea con fines académicos a partir de información pública. Los hechos atribuidos a la organización se sustentan en las fuentes citadas; los síntomas que no pueden verificarse públicamente se presentan como supuestos del caso.

Sector y organización. El caso pertenece al sector educación. La organización es la Secretaría de Educación del Distrito (SED) de Bogotá, entidad del sector central de la Alcaldía Mayor, con sede principal en la Avenida El Dorado n.º 66-63 y direcciones locales en las 20 localidades de la ciudad. Según su directorio georreferenciado, en septiembre de 2026 la ciudad contaba con 417 establecimientos oficiales y 1.401 no oficiales (2.176 sedes); según el Ministerio de Educación Nacional (MEN), la matrícula de Bogotá pasó de 1.344.395 estudiantes en 2016 a 1.147.611 en 2025 (cálculo propio con datos del MEN, 2026).

El problema. El examen Saber 11 es la principal medición externa de la calidad de la educación media. Con los datos abiertos del Instituto Colombiano para la Evaluación de la Educación (ICFES) se observa que el puntaje global promedio de Bogotá venía bajando desde antes de la pandemia (aplicación del segundo semestre, calendario A: 277,1 en 2016 y 265,8 en 2019) y que en 2022 la recuperación fue desigual: los colegios no oficiales subieron 8,4 puntos frente a 2019, mientras los oficiales subieron 2,6. Así, la brecha entre ambos sectores pasó de 24,9 a 30,7 puntos (cálculo propio con datos del ICFES, 2026). En el mismo periodo, la tasa de deserción de los colegios oficiales pasó de 1,60 % en 2019 a 3,48 % en 2022, con valores de 8,08 % en La Candelaria y 5,78 % en Santa Fe (SED, 2023).

Decisor. El decisor es el (la) subsecretario(a) de Calidad y Pertinencia de la SED, responsable de priorizar los programas de acompañamiento pedagógico y refuerzo para la educación media en los colegios oficiales.

Decisión que no puede tomar hoy. La Subsecretaría no puede decidir con evidencia a qué colegios oficiales y a qué localidades enviar primero los programas de refuerzo, porque no tiene en un solo lugar el resultado de cada colegio a lo largo del tiempo, su localidad y su tamaño. El ICFES identifica al colegio por código DANE pero no por localidad; la localidad solo está en el directorio de la SED, y la matrícula en las estadísticas del MEN. Cada año, el boletín estadístico de la SED consolida estas cifras a mano en un PDF, sin la posibilidad de bajar al nivel de colegio ni de comparar su evolución.

Qué propone la consultora. Integrar en un almacén de datos los resultados individuales del Saber 11 de 2016 a 2022 (ICFES), el directorio de colegios con localidad, UPZ y coordenadas (SED) y la matrícula anual por establecimiento (MEN), para responder las preguntas de la sección 1.3 con un tablero por localidad y un modelo que estime el puntaje esperado de cada colegio oficial.

1.2 Síntomas de arquitectura accidental

#	Síntoma	Evidencia en el caso	Capa afectada
S1	Cada entidad identifica al mismo colegio con un código y formato distinto.	El ICFES usa el código DANE como texto ("111001000132"); el MEN lo exporta con puntos de miles ("111.001.000.132"); la SED lo separa en establecimiento y sede (DANE12_EST, DANE12_SED). Solo el 94,4 % de las filas del ICFES encuentra su colegio en el directorio de la SED.	Fuentes / Integración

#	Síntoma	Evidencia en el caso	Capa afectada
S2	Los canales oficiales de un mismo conjunto de datos no coinciden entre sí.	El archivo de colegios de la SED trae 2.176 sedes con corte 30/09/2026, y el servicio REST del mismo conjunto, 2.211 sedes con corte 31/12/2025 (41 sedes solo en la API y 6 solo en el archivo). El sistema de coordenadas declarado (EPSG 4686 y 4326) no coincide con el del archivo (EPSG 3857) (SED, 2025b).	Fuentes / Gobierno
S3	Los diccionarios de códigos se contradicen.	En el catálogo de objetos de la SED, NATU_JUR 17 significa "Universidad"; en el servicio REST, 17 es "Distrital" y 19 es "Universidad". El informe oficial de calidad reporta 0 errores de dominio para ese campo (SED, 2025a, 2025c).	Gobierno / Metadatos
S4	Los resultados llegan duplicados y con periodos faltantes.	En el Saber 11 de Bogotá, cada estudiante de 2019 y 2022 aparece dos veces (159.417 filas duplicadas) y faltan los periodos 2018-2, 2020-2 y 2021-2, aunque el conjunto dice cubrir de 2010 a 2022.	Fuentes / Integración
S5	Los indicadores clave se consolidan a mano en boletines PDF.	La deserción por localidad solo se publica en el boletín estadístico anual de la SED, un año por documento y con un número de tabla distinto cada año (Tabla 88 en 2020, 87 en 2021, 83 en 2022, 84 en 2023) (SED, 2020, 2021, 2022, 2023).	Usuario final / Almacén

1.3 Preguntas de negocio

#	Pregunta	Tipo (BI, BA o Big Data)	Por qué es de ese tipo
P0	¿En qué localidades de Bogotá creció más la brecha de puntaje global del Saber 11 entre colegios no oficiales y oficiales al comparar 2016-2019 con 2022?	BI	Describe y compara lo que ya ocurrió con datos históricos estructurados (resultados 2016-2022) agregados por localidad y sector.
P1	¿Qué colegios oficiales no recuperaron en 2022 su puntaje global promedio de 2016-2019?	BI	Compara el desempeño histórico de cada colegio en dos periodos; es descriptiva.
P2	¿Cómo cambió la diferencia de puntaje entre estudiantes con y sin internet en el hogar antes y después de la pandemia?	BI	Cruza una variable de contexto ya registrada con el resultado histórico para explicar lo ocurrido; no predice.

#	Pregunta	Tipo (BI, BA o Big Data)	Por qué es de ese tipo
P3	¿Qué puntaje global se espera para cada colegio oficial en la próxima aplicación, según su historia, su localidad, su matrícula y el perfil de sus estudiantes, y cuáles deben priorizarse para refuerzo?	BA	Busca predecir un valor futuro con un modelo entrenado sobre el histórico y recomendar una acción (priorizar colegios). No es Big Data: son menos de 400.000 registros estructurados.
P4	¿Existe relación entre el tamaño del colegio (matrícula) y su puntaje promedio en cada sector?	BI	Analiza la relación entre dos variables históricas ya medidas, agregadas por colegio y año.

2. Inventario de fuentes

F1. Resultados únicos Saber 11 (ICFES). Conjunto de datos oficial del Instituto Colombiano para la Evaluación de la Educación en el Portal Nacional de Datos Abiertos (ICFES, 2026), con los resultados anonimizados de cada estudiante por aplicación del examen, los datos del colegio y variables socioeconómicas del hogar. Se descargó filtrado a Bogotá (código de departamento 11) y a los periodos de 2016 a 2022 mediante la API pública del portal. Es la fuente de la tabla de hechos.

F2. Colegios. Bogotá D.C. (Secretaría de Educación del Distrito). Directorio georreferenciado de las sedes educativas oficiales y no oficiales de Bogotá, publicado en Datos Abiertos Bogotá a partir del Directorio Único de Establecimientos (DUE) (SED, 2026a). Aporta la localidad, la UPZ, las coordenadas y la clasificación de cada sede. Los códigos se interpretan con el catálogo de objetos de la SED (SED, 2025a) y el diccionario del servicio REST del mismo conjunto (SED, 2026b).

F3. Establecimientos educativos de preescolar, básica y media (Ministerio de Educación Nacional). Registro anual de los establecimientos del país (MEN, 2026), de 2015 a 2025, con sector, calendario, número de sedes y matrícula total. Para Bogotá aporta 22.512 registros (unos 2.000 establecimientos por año) y permite conocer el tamaño de cada colegio en el año de cada aplicación.

Las tres fuentes son datos reales; no se usan datos sintéticos. Como documentos de apoyo se usan el catálogo de objetos, la especificación técnica y la evaluación de calidad del conjunto de colegios (SED, 2025a, 2025b, 2025c), y los boletines estadísticos anuales de la SED (SED, 2023), cuyas tablas de resultados Saber 11 por localidad sirven para conciliar los cálculos del almacén. La tabla de hechos tomará de F1 los 361.719 resultados únicos de 2016 a 2022 (más de 50.000 filas y siete años de historia).

2.1 Fuentes

Fuente	Procedencia (URL)	Formato	Registros	Periodo	Fecha de descarga	Licencia
F1	https://www.datos.gov.co/Educaci-n/Resultados-nicos-Saber-11/kgxf-xxbe	CSV (API del portal)	523.922 (361.719 únicos)	2016-1 a 2022-2	22/10/2026	CC BY-SA 4.0
F2	https://datosabiertos.bogota.gov.co/dataset/colegios-bogota-d-c	GeoJSON	2.176 sedes (1.818 colegios)	Corte 30/09/2026	22/10/2026	CC BY-SA 4.0

Fuente	Procedencia (URL)	Formato	Registros	Periodo	Fecha de descarga	Licencia
F3	https://www.datos.gov.co/Educaci-n/MEN_ESTABLECIMIENTOS_EDUCATIVOS_PREESCOLAR_B-SICA_/cfw5-qzt5	CSV	606.206 (22.512 de Bogotá)	2015 a 2025	22/10/2026	CC BY-SA 4.0

2.2 Problemas de calidad detectados

Fuente	Campo	Problema	Ejemplo real del dato
F1	Todas (filas)	Registros duplicados: cada estudiante de 2019 y 2022 aparece dos veces.	SB11201940000018 aparece dos veces idéntico; 2019-2 tiene 165.918 filas y 82.832 estudiantes.
F1	PERIODO	El mismo tipo de aplicación cambia de código y faltan periodos.	Segundo semestre: "20172" hasta 2017 y "20194" desde 2019; no existen 20182, 20204 ni 20214.
F1	COLE_DEPTO_UBICACION	El mismo departamento escrito de dos formas.	"BOGOTÁ" (330.259 filas) y "BOGOTA" (193.663 filas).
F2	Geometría	El sistema de coordenadas del archivo no coincide con el documentado.	Archivo en EPSG 3857 (Aquileo Parra: -8242002,85; 531131,02); especificación EPSG 4686; metadato EPSG 4326.
F2	SECTOR / NATU_JUR	Campos codificados sin etiqueta y diccionarios contradictorios.	SECTOR 1 = No oficial y 2 = Oficial; NATU_JUR 19: no existe en el catálogo PDF y es "Universidad" en el servicio REST.
F2	Archivo vs. servicio	Dos canales oficiales con distinta cobertura y fecha de corte.	Archivo: 2.176 sedes, 30/09/2026; servicio REST: 2.211 sedes, 31/12/2025.
F3	AÑO / CODIGO_DANE	Números exportados con punto de miles.	AÑO "2.015"; CODIGO_DANE "111.001.000.132"; TOTAL_MATRICULA "3.201".
F3	Filas del año 2023	Volumen anómalo y códigos incompletos en un año.	2023 tiene 416.716 filas en el país (≈19.000 los demás años) y solo 24 códigos DANE distintos para Bogotá.
F3	CARACTER	Valores vacíos representados con guion.	CARACTER = "-" en el 5 % de los registros de Bogotá.

Los diccionarios completos de cada fuente están en el Anexo A y en /datos/diccionarios; la muestra de 20 filas por fuente está en /datos/muestras del repositorio.

3. Diagnóstico de madurez

El diagnóstico usa el modelo de madurez de BI (BIMM) de siete fases visto en clase: 1. No existe BI · 2. Datos accesibles sin BI · 3. Procesos formales de decisión basados en datos · 4. Data warehouse · 5. Crecimiento del DW y reporting formal · 6. Despliegue de OLAP · 7. BI formalizado.

Elemento	Respuesta
Fase actual	Fase 2 · Datos accesibles sin BI ("No existe BI, pero los datos son accesibles").
Evidencia	S1: los datos de las tres entidades son públicos y accesibles, pero cada uno usa un código distinto para el mismo colegio. S4: los resultados se publican con duplicados y periodos faltantes que nadie depura antes de usarlos. S5: los indicadores se consolidan a mano en un boletín PDF por año, no en un proceso de decisión basado en datos integrados.
Por qué no es la fase siguiente	Para estar en la fase 3 (Procesos formales de decisión basados en datos) la SED necesitaría indicadores definidos y calculados periódicamente con datos consolidados por colegio (por ejemplo, brecha oficial / no oficial por localidad o colegios que no recuperan su nivel) y un procedimiento que los use para asignar los programas de refuerzo. Hoy no existe una base integrada ni una llave común confiable entre fuentes (S1, S2).
Fase objetivo al final del proyecto	Fase 4 · Data warehouse.
Brechas que cierra el proyecto	1. Integración manual de fuentes → Capa 2: transformaciones y job de Pentaho PDI con carga a staging. 2. Sin repositorio histórico único → Capa 3: almacén dimensional en MySQL (esquema estrella). 3. Sin llave común entre entidades → Capas 2 y 3: homologación del código DANE y dimensión Colegio conformada. 4. Indicadores solo en PDF y sin predicción → Capa 4: tablero en Power BI y notebook de Python con el modelo. 5. Diccionarios contradictorios y sin control de calidad → Capa 5: diccionarios, conciliación y registro de cargas.

4. Arquitectura

La arquitectura propuesta sigue las cinco capas vistas en clase. Las tres fuentes públicas (capa 1) se extraen con Pentaho Data Integration, que las limpia, homologa y carga primero en una base de datos de staging y luego en el almacén dimensional en MySQL (capas 2 y 3). Sobre el almacén se construyen el tablero en Power BI y los notebooks de Python con el modelo predictivo (capa 4). La capa transversal de gobierno documenta las fuentes, traduce los códigos con los diccionarios oficiales, concilia los resultados contra las cifras publicadas por la SED y versiona todo en GitHub (capa 5). La carga es anual, al ritmo de las publicaciones del ICFES, del MEN y de la SED.

4.1 Diagrama de cinco capas del caso

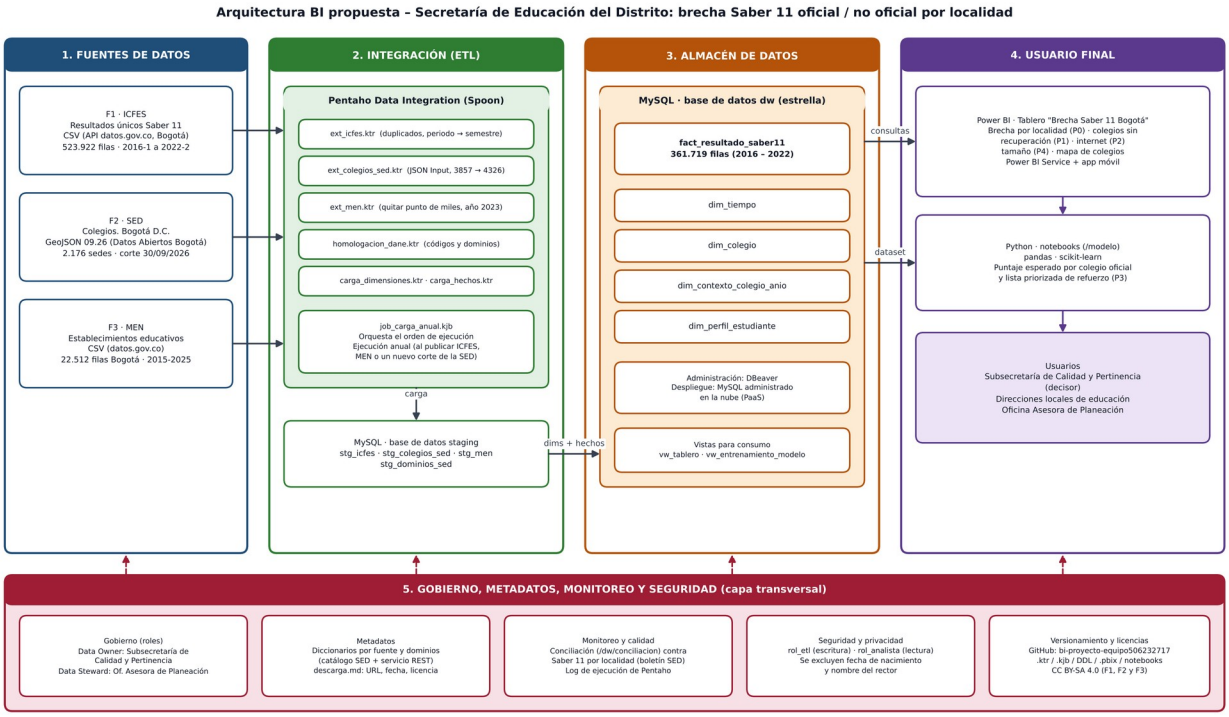


Figura 1. Arquitectura de cinco capas propuesta (versión ampliada en el Anexo B; PNG y archivo draw.io en /docs/diagramas). Fuente: elaboración propia.

4.2 Componentes por capa

Capa	Componentes y herramientas del caso	Función en el caso
1. Fuentes de datos	F1 ICFES: CSV descargado de la API de datos.gov.co (filtro Bogotá, 2016-2022). F2 SED: GeoJSON 09.26 de Datos Abiertos Bogotá. F3 MEN: CSV de datos.gov.co.	Proveer los resultados por estudiante, la ubicación y clasificación de cada sede y la matrícula anual de cada establecimiento. Los archivos originales se guardan sin modificar en /datos/raw.
2. Integración (ETL)	Pentaho Data Integration (Spoon): transformaciones ext_icfes.ktr, ext_colegios_sed.ktr (paso JSON Input), ext_men.ktr, homologacion_dane.ktr, carga_dimensiones.ktr y carga_hechos.ktr; job_carga_anual.kjb con ejecución anual (al publicarse los resultados del ICFES y la matrícula del MEN). Carga a una base de datos staging en MySQL.	Quitar duplicados del ICFES, crear semestre y calendario desde PERIODO, quitar puntos de miles del MEN, convertir coordenadas de EPSG 3857 a 4326 (paso Formula), traducir códigos con el catálogo y homologar el código DANE.
3. Almacén de datos	MySQL, base de datos dw con fact_resultado_saber11 y las dimensiones dim_tiempo, dim_colegio, dim_contexto_colegio_anio y dim_perfil_estudiante; administrado con DBeaver.	Guardar el histórico integrado 2016-2022 en un esquema estrella para consultas por localidad, sector, colegio, año y perfil del estudiante.

Capa	Componentes y herramientas del caso	Función en el caso
4. Usuario final	Tablero en Power BI ("Brecha Saber 11 Bogotá") publicado en Power BI Service con mapa de colegios y acceso móvil; notebooks de Python (pandas, scikit-learn) con el modelo de puntaje esperado por colegio.	Responder P0, P1, P2 y P4 para la Subsecretaría de Calidad y Pertinencia y las direcciones locales, y P3 con la lista priorizada de colegios oficiales para refuerzo.
5. Gobierno, metadatos, monitoreo y seguridad	Roles de gobierno: Data Owner, la Subsecretaría de Calidad y Pertinencia (aprueba la definición de los indicadores), y Data Steward, la Oficina Asesora de Planeación de la SED (mantiene el catálogo y los diccionarios). Repositorio GitHub (diccionarios en /datos/diccionarios, trazabilidad en /datos/descarga.md), consultas de conciliación en /dw/conciliacion contra las tablas de Saber 11 por localidad de los boletines SED, log de Pentaho, roles de MySQL (rol_etl, rol_analista) y exclusión en el ETL de la fecha de nacimiento del estudiante y del nombre del rector.	Asegurar trazabilidad (fuente, fecha, licencia), validar conteos y promedios contra cifras oficiales, usar un único diccionario de códigos y proteger a los estudiantes evitando cuasi-identificadores en el almacén.

4.3 Marco de Referencia de cuatro categorías

Categoría	Decisión tomada	Justificación
Arquitectura de información	La Subsecretaría necesita: puntaje global y por área por colegio y año, brecha oficial / no oficial por localidad, colegios que no recuperan su nivel, perfil socioeconómico de los estudiantes y tamaño del colegio. Indicadores: puntaje promedio, brecha entre sectores, variación frente a 2016-2019 y puntaje esperado.	Se deriva de las preguntas P0 a P4 y de la decisión del caso (a qué colegios y localidades dirigir el refuerzo). Va primero porque define qué datos hay que integrar.
Arquitectura de datos	Modelo dimensional en estrella con granularidad de resultado por estudiante y aplicación; bases de datos staging y dw; carga anual incremental por periodo publicado.	El nivel más fino disponible es el estudiante, lo que permite agregar a colegio, localidad o sector sin perder información y armar el conjunto de entrenamiento del modelo.
Arquitectura técnica	Pentaho Data Integration para el ETL, MySQL para el almacén, Python para el modelo y GitHub para versionar; base de datos desplegada en la nube (PaaS).	Son herramientas libres o vistas en el curso, sin costo de licencia para una entidad pública; el volumen (menos de 400.000 hechos) no requiere tecnologías de Big Data.
Arquitectura de producto	Tablero en Power BI con páginas por pregunta (brecha por localidad, colegios sin recuperación, conectividad, tamaño) y un mapa de colegios, más un notebook con el puntaje esperado por colegio.	Los usuarios de la Subsecretaría y de las direcciones locales no son técnicos: necesitan filtros simples, mapa y una lista priorizada que puedan usar para asignar los programas.

4.4 Decisión de despliegue

Criterio	On-premise	Opción cloud: PaaS	Elegida y por qué
Costo	Compra de servidor, licencias de sistema operativo, respaldo y personal de TI: inversión inicial alta para un volumen pequeño.	Pago por uso; una base de menos de 2 GB y un servidor pequeño tienen costo mensual bajo, sin compra de hardware.	Cloud PaaS: el volumen es pequeño y el costo variable es menor que comprar y mantener un servidor.
Seguridad y cumplimiento	Control total de la infraestructura, pero la SED debe gestionar parches, copias de seguridad y accesos.	Cifrado, copias automáticas y control de acceso por roles del proveedor; los datos son públicos y anonimizados.	Cloud PaaS: los datos ya son abiertos y anonimizados, y el ETL excluye cuasi-identificadores como la fecha de nacimiento.
Escalabilidad	Limitada al hardware comprado; crecer implica nueva compra.	Se puede aumentar la capacidad en minutos al agregar años o fuentes (por ejemplo, Saber 3°, 5° y 9°).	Cloud PaaS: permite crecer hacia la fase 5 sin rediseñar.
Acceso móvil	Requiere VPN o publicar servicios internos para consultar fuera de la sede.	Power BI Service ofrece aplicación móvil con el mismo tablero y permisos.	Cloud PaaS: las direcciones locales consultan el tablero desde las 20 localidades.

Opción elegida: nube PaaS. El costo, la seguridad (datos abiertos y anonimizados), la escalabilidad y el acceso desde las localidades favorecen la nube frente a un servidor propio. La base de datos se despliega como MySQL administrado (PaaS) y el tablero se publica en Power BI Service (SaaS).

5. Modelo dimensional

Se eligió un modelo dimensional en estrella con una tabla de hechos de resultados del Saber 11 y cuatro dimensiones: Tiempo (aplicación del examen), Colegio (sede, establecimiento, UPZ y localidad), Contexto del colegio en el año (matrícula del MEN) y Perfil del estudiante (condiciones del hogar). Así se puede comparar el desempeño por localidad y sector, seguir a cada colegio en el tiempo y relacionar el puntaje con el contexto.

5.1 Proceso de negocio

El proceso de negocio modelado es la evaluación externa de la educación media mediante el examen de Estado Saber 11. En cada aplicación, el ICFES registra el resultado de cada estudiante (puntaje global y por área), el colegio en el que cursa grado once y la información del hogar reportada al inscribirse. Para la SED, cada resultado es la medición del logro de un estudiante de un colegio de la ciudad; agregados por colegio, localidad y sector, permiten evaluar la calidad educativa y decidir dónde intervenir.

5.2 Granularidad

Una fila de la tabla de hechos representa el resultado de un estudiante en una aplicación del examen Saber 11, presentado en un colegio de Bogotá.

5.3 Métricas de la tabla de hechos

Métrica	Tipo de dato	Aditividad	Origen o fórmula
punt_global	SMALLINT (0-500)	No aditiva	F1.PUNT_GLOBAL; se agrega con promedio

Métrica	Tipo de dato	Aditividad	Origen o fórmula
punt_lectura_critica	SMALLINT (0-100)	No aditiva	F1.PUNT_LECTURA_CRITICA; se agrega con promedio
punt_matematicas	SMALLINT (0-100)	No aditiva	F1.PUNT_MATEMATICAS; se agrega con promedio
punt_sociales_ciudadanas	SMALLINT (0-100)	No aditiva	F1.PUNT_SOCIALES_CIUDADANAS; se agrega con promedio
punt_c_naturales	SMALLINT (0-100)	No aditiva	F1.PUNT_C_NATURALES; se agrega con promedio
punt_ingles	SMALLINT (0-100)	No aditiva	F1.PUNT_INGLES; se agrega con promedio
cantidad_estudiantes	SMALLINT	Aditiva	Constante 1 por fila; su suma da el número de evaluados

5.4 Dimensiones

Dimensión	Atributos principales	Jerarquía	Fuente
Tiempo (dim_tiempo)	sk_tiempo, periodo (código ICFES), anio, semestre, calendario_aplicacion (A/B), etapa (prepandemia / pandemia / pospandemia)	periodo → semestre → año → etapa	F1 (PERIODO) + generada
Colegio (dim_colegio)	sk_sede, cod_dane_sede, cod_dane_establecimiento, nombre_sede, nombre_establecimiento, sector, clase, jornada, calendario, bilingüe, zona, upz, localidad, latitud, longitud	sede → establecimiento → UPZ → localidad	F1 (COLE_*) + F2 (localidad, UPZ, coordenadas, códigos)
Contexto del colegio en el año (dim_contexto_colegio_anio)	sk_contexto, cod_dane_establecimiento, anio, total_matricula, rango_matricula (pequeño / mediano / grande), cantidad_sedes, sector_men	Sin jerarquía (una fila por establecimiento y año)	F3 (MEN)
Perfil del estudiante (dim_perfil_estudiante)	sk_perfil, genero, estrato_vivienda, tiene_internet, tiene_computador, educacion_madre, educacion_padre	Sin jerarquía (combinaciones de perfil)	F1 (ESTU_GENERO, FAMI_*)

5.5 Diagrama del esquema

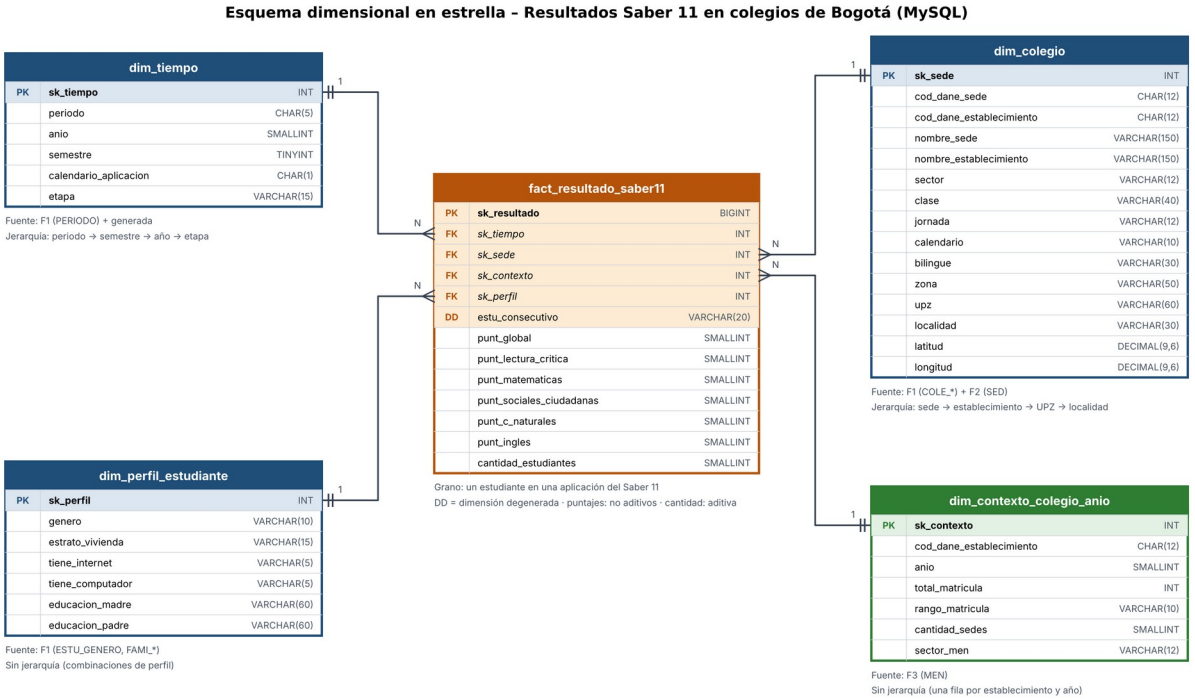


Figura 2. Esquema dimensional en estrella con llaves primarias (PK) y foráneas (FK) (versión ampliada en el Anexo B; PNG y archivo draw.io en /docs/diagramas). Fuente: elaboración propia.

Se eligió un esquema en estrella y no un copo de nieve. La jerarquía del colegio (sede → establecimiento → UPZ → localidad) y la del tiempo tienen pocos miembros —1.323 sedes con resultados y 11 periodos — y se guardan desnormalizadas en la misma tabla, lo que evita uniones adicionales, simplifica las consultas del tablero y facilita armar el conjunto de entrenamiento del modelo. El perfil del estudiante se agrupa en una sola dimensión de combinaciones (mini-dimensión) para no repetir texto en cada hecho. La dimensión de contexto se asigna en el ETL por código de establecimiento y año de la aplicación; los colegios sin dato en el MEN o sin pareja en el directorio de la SED apuntan a un miembro "Sin dato". El identificador anonimizado del estudiante (ESTU_CONSECUTIVO) se conserva en la tabla de hechos como dimensión degenerada, y cada hecho tiene una llave primaria sustituta (sk_resultado) más una llave foránea hacia cada dimensión.

5.6 Trazabilidad con las preguntas

Pregunta	Métricas que usa	Dimensiones que usa
P0	punt_global, cantidad_estudiantes	Tiempo (etapa, año), Colegio (sector, localidad)
P1	punt_global	Tiempo (etapa), Colegio (establecimiento, sector = oficial, localidad)
P2	punt_global, cantidad_estudiantes	Tiempo (etapa), Perfil del estudiante (tiene_internet), Colegio (sector)
P3	punt_global (variable a predecir), puntajes por área	Tiempo (año), Colegio (establecimiento, localidad, sector, jornada), Contexto (total_matricula), Perfil del estudiante

Pregunta	Métricas que usa	Dimensiones que usa
P4	punt_global, cantidad_estudiantes	Contexto (total_matricula, rango_matricula), Colegio (sector), Tiempo (año)

6. Referencias

Instituto Colombiano para la Evaluación de la Educación. (2026). *Resultados únicos Saber 11* [Conjunto de datos]. Portal Nacional de Datos Abiertos. https://www.datos.gov.co/Educaci-n/Resultados-nicos-Saber-11/kgxf-xxbe

Ministerio de Educación Nacional. (2026). *MEN_ESTABLECIMIENTOS_EDUCATIVOS_PREESCOLAR_BÁSICA_Y_MEDIA* [Conjunto de datos]. Portal Nacional de Datos Abiertos. https://www.datos.gov.co/Educaci-n/MEN_ESTABLECIMIENTOS_EDUCATIVOS_PREESCOLAR_B-SICA_/cfw5-qzt5

Secretaría de Educación del Distrito. (2020). *Caracterización del sector educativo Bogotá D.C. 2020*. https://www.educacionbogota.edu.co/portal_institucional/conoce-nuestras-cifras

Secretaría de Educación del Distrito. (2021). *Caracterización del sector educativo Bogotá D.C. 2021*. https://www.educacionbogota.edu.co/portal_institucional/conoce-nuestras-cifras

Secretaría de Educación del Distrito. (2022). *Caracterización del sector educativo de Bogotá, año 2022*. https://www.educacionbogota.edu.co/portal_institucional/conoce-nuestras-cifras

Secretaría de Educación del Distrito. (2023). *Caracterización del sector educativo Bogotá D.C. 2023*. https://www.educacionbogota.edu.co/portal_institucional/conoce-nuestras-cifras

Secretaría de Educación del Distrito. (2025a). *Diccionario de conceptos y catálogo de objetos del objeto geográfico Colegio*. https://catalogopmb.catastrobogota.gov.co/PMBWeb/cr/hie/web?cmd=output&ID_REGISTRO=2990&TIPO=GIG-05-FR-01_V2_CATALOGODEOBJETOS&FORMATO=pdf

Secretaría de Educación del Distrito. (2025b). *Especificación técnica del objeto Colegio*. https://catalogopmb.catastrobogota.gov.co/PMBWeb/cr/hie/web?cmd=output&ID_REGISTRO=2990&TIPO=GIG-05-FR-03_V2_ESPECIFICACIONESTECNICAS&FORMATO=pdf

Secretaría de Educación del Distrito. (2025c). *Evaluación y reporte de calidad del objeto geográfico Colegio*. https://catalogopmb.catastrobogota.gov.co/PMBWeb/cr/hie/web?cmd=output&ID_REGISTRO=2990&TIPO=GIG-05-FR-05_V2_EVALUACIONDECALIDAD&FORMATO=pdf

Secretaría de Educación del Distrito. (2026a). *Colegios. Bogotá D.C.* [Conjunto de datos]. Datos Abiertos Bogotá. https://datosabiertos.bogota.gov.co/dataset/colegios-bogota-d-c

Secretaría de Educación del Distrito. (2026b). *Colegios (ID: 0)* [Servicio REST]. https://serviciosgis.catastrobogota.gov.co/arcgis/rest/services/educacion/infraestructuraeducativa/MapServer/0

Anexos

Anexo A. Diccionarios de datos

A.1 F1 – Resultados únicos Saber 11 (ICFES), 51 campos; se listan los usados en el modelo

Campo	Tipo	Descripción	Ejemplo	Problema de calidad
PERIODO	Texto	Año + aplicación (1 = primer semestre, 2 o 4 = segundo)	20224	Cambia de ...2 a ...4; faltan periodos.
ESTU_CONSECUTIVO	Texto	Identificador anonimizado del evaluado	SB11201940000018	Duplicado en 2019 y 2022.
COLE_COD_DANE_ESTABLECIMIENTO	Texto	Código DANE del colegio	111001000132	Sin pareja en la SED para el 5,6 % de filas.
COLE_COD_DANE_SEDE	Texto	Código DANE de la sede	111001000132	Sin problema detectado.
COLE_NATURALEZA	Texto	Oficial o no oficial	OFICIAL	Etiqueta distinta a la de la SED (SECTOR 1/2).
COLE_AREA_UBICACION	Texto	Urbano o rural	URBANO	Solo 1 % rural en Bogotá.
COLE_JORNADA	Texto	Jornada de la sede	MAÑANA	Valores mezclan jornada y modalidad (NOCHE, SABATINA).
COLE_DEPTO_UBICACION	Texto	Departamento del colegio	BOGOTÁ	"BOGOTÁ" y "BOGOTA".
ESTU_GENERO	Texto	Género del evaluado	F	Sin problema detectado.
ESTU_FECHANACIMIENTO	Texto (fecha)	Fecha de nacimiento	17/10/2003	Cuasi-identificador: se excluye en el ETL.
FAMI_ESTRATOVIVIENDA	Texto	Estrato de la vivienda	Estrato 2	17.773 vacíos y valor "Sin Estrato".
FAMI_TIENEINTERNET	Texto	Hogar con internet	Si	17.211 vacíos.
PUNT_GLOBAL	Número	Puntaje global (0-500)	190	Sin vacíos.
PUNT_MATEMATICAS	Número	Puntaje de matemáticas (0-100)	35	Sin problema detectado.

A.2 F2 – Colegios. Bogotá D.C. (SED), 31 campos; se listan los usados en el modelo

Campo	Tipo	Descripción	Ejemplo	Problema de calidad
DANE12_EST	Texto	Código DANE del establecimiento	111001000132	Solo sedes vigentes en 2026; faltan colegios cerrados.
DANE12_SED	Texto	Código DANE de la sede	111001000132	Sin duplicados (verificado).
NOMBRE_EST	Texto	Nombre del establecimiento	COLEGIO AQUILEO PARRA (IED)	Texto libre; no sirve como llave.
SECTOR	Entero (código)	1 No oficial · 2 Oficial	2	Código sin etiqueta en el archivo.
NATU_JUR	Entero (código)	Naturaleza jurídica	9	Dominio distinto en catálogo y servicio REST.
CLASE_TIPO	Entero (código)	1 Distrital ... 6 Privado régimen especial	4	Código sin etiqueta.
CALENDARIO	Entero (código)	1 A · 2 A-B · 3 B · 4 B-Otro · 5 Otro	1	Código sin etiqueta.

Campo	Tipo	Descripción	Ejemplo	Problema de calidad
ZONA	Entero (código)	1 Urbana · 2 Rural · 3-6 mixtas	1	Sin dominio en el catálogo PDF.
COD_LOCA	Texto (código)	Localidad (01-20)	01	Alias "Nombre de la localidad" pero trae código.
NOM_UPZ	Texto (código)	UPZ	9	Se llama "NOM" pero trae código.
ESTRATO	Texto (código)	Estrato del predio (0 y 7 = sin dato)	7	Códigos de "sin dato" mezclados con estratos.
FECHA	Fecha	Fecha de corte	2026-09-30	El servicio REST dice 2025-12-31.
geometry	Punto	Ubicación de la sede	(-8242002,85; 531131,02)	En EPSG 3857, no en grados.

A.3 F3 – Establecimientos educativos (MEN), 24 campos; se listan los usados en el modelo

Campo	Tipo	Descripción	Ejemplo	Problema de calidad
AÑO	Texto	Año del registro	2.015	Punto de miles en el año.
COD_DANE_DEPARTAMENTO	Texto	Código del departamento	11	Sin problema detectado.
CODIGO_DANE	Texto	Código DANE del establecimiento	111.001.000.132	Punto de miles; 2023 casi sin códigos.
NOMBRE_ESTABLECIMIENTO	Texto	Nombre del colegio	COLEGIO AQUILEO PARRA (IED)	Texto libre; no sirve como llave.
SECTOR	Texto	OFICIAL / NO_OFICIAL	NO_OFICIAL	Tercera forma de escribir el sector.
CALENDARIO	Texto	Calendario académico	A	Sin problema detectado.
CARACTER	Texto	Carácter de la media	-	Vacíos escritos como "-".
TOTAL_MATRICULA	Número	Estudiantes matriculados	3.201	Punto de miles.
CANTIDAD_SEDES	Número	Número de sedes	1	Sin problema detectado.
RECTOR	Texto	Nombre del rector	(se omite)	Dato personal: se excluye en el ETL y en la muestra.

Anexo B. Diagramas a tamaño completo

Diagramas en tamaño de página. Los archivos fuente (PNG y draw.io) están en /docs/diagramas del repositorio.

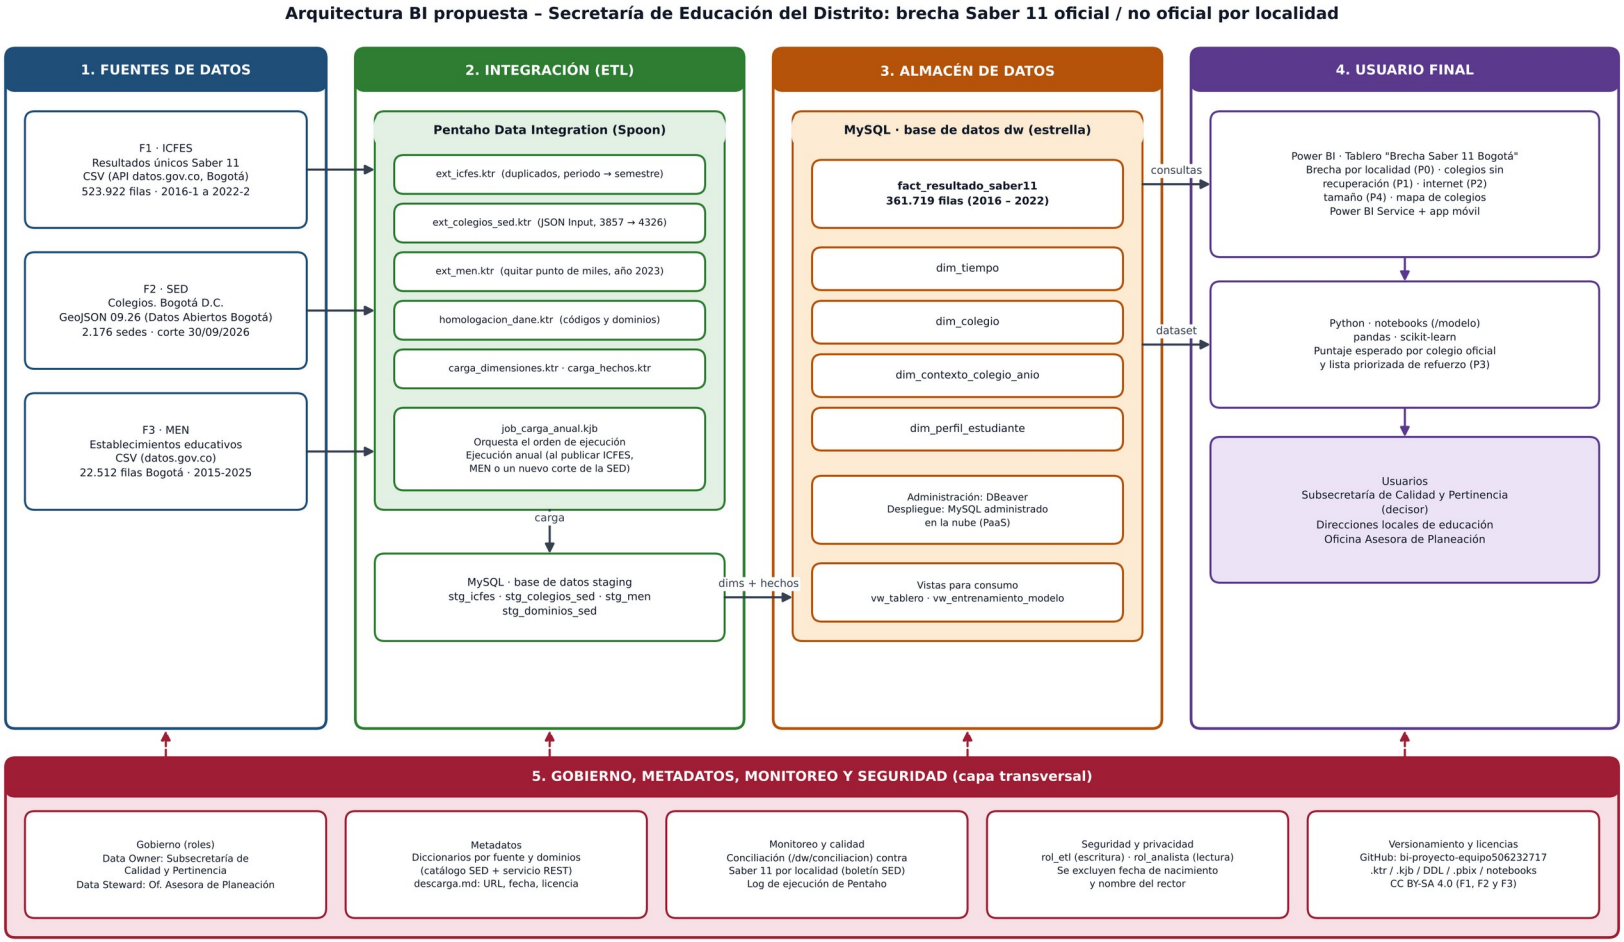


Figura B1. Arquitectura de cinco capas. Fuente: elaboración propia.

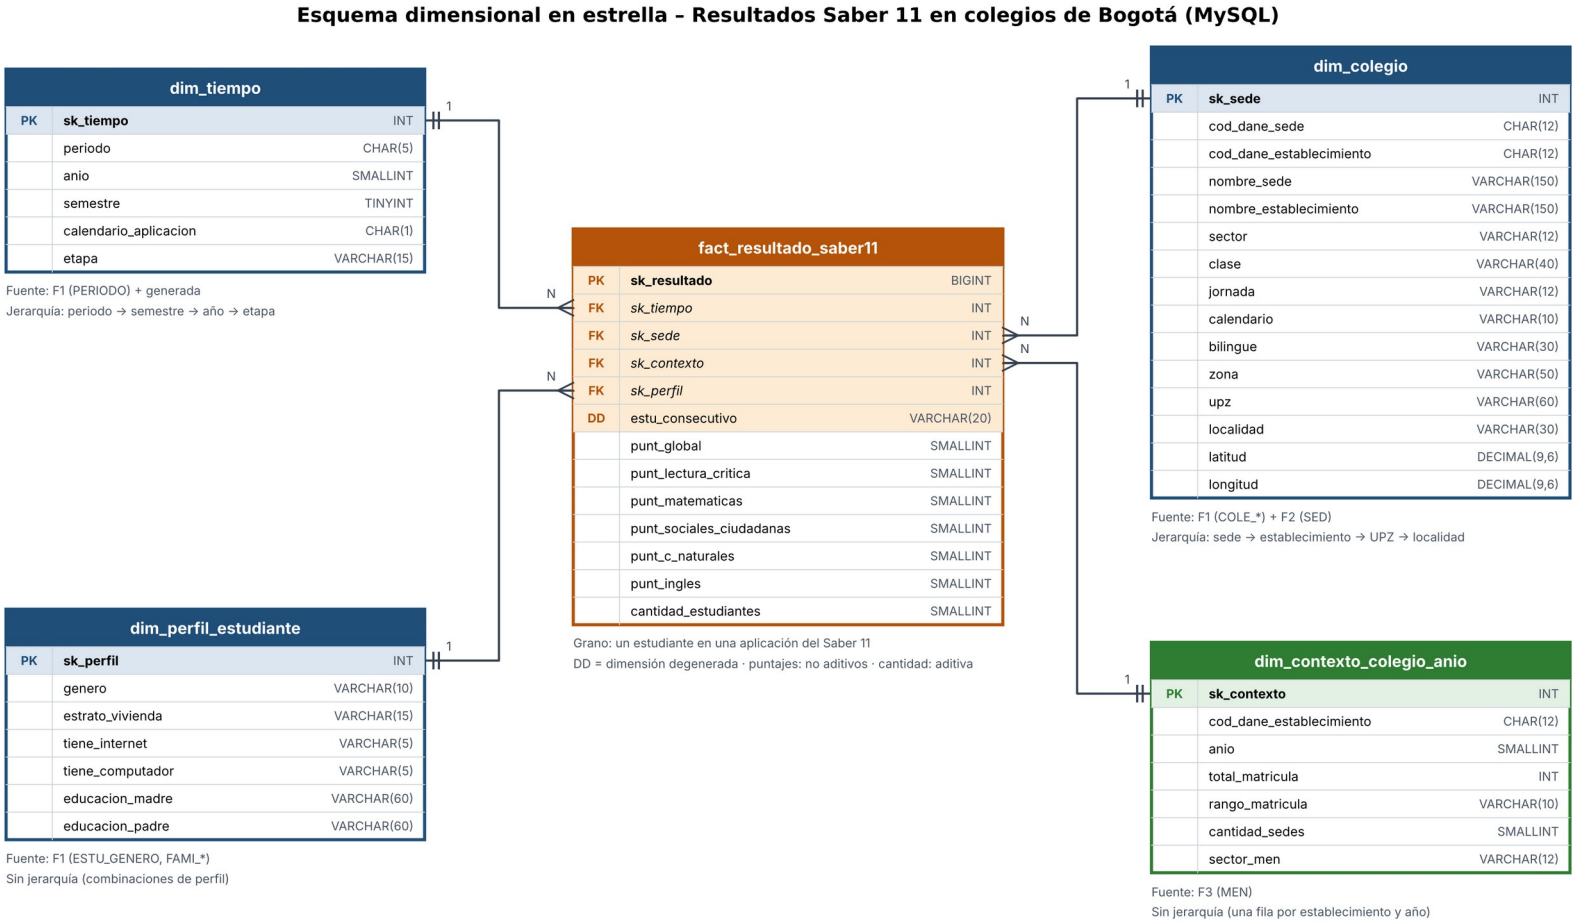


Figura B2. Esquema dimensional en estrella. Fuente: elaboración propia.