Business Intelligence

Proyecto final · Entrega 2

Data warehouse, ETL y tablero

Secretaría de Educación del Distrito de Bogotá: ¿la pandemia amplió la brecha entre colegios oficiales y no oficiales en el Saber 11?

Integrante	Código
Laura Valentina López García	506232714
Juan Camilo Prieto Mestizo	506232717
Diego Alejandro Gil Moreno	507232716

Dato	Valor
Docente	Leandro Pájaro Fuentes
Fecha de entrega	06/11/2026
Repositorio	https://github.com/KamiroDark/bi-proyecto-equipo506232717
Motor de base de datos	MySQL 8.4 (Aiven, en la nube)
Herramienta del tablero	Power BI Desktop

Resumen de la entrega

Se construyó el data warehouse dw en MySQL 8.4 (Aiven) con un esquema en estrella de cinco tablas: la tabla de hechos fact_resultado_saber11 y las dimensiones dim_tiempo, dim_colegio, dim_contexto_colegio_anio y dim_perfil_estudiante. Un solo trabajo de Pentaho Data Integration (job_carga_dw.kjb) recrea las tablas y ejecuta cinco transformaciones: la del calendario y cuatro que leen las tres fuentes en su formato original (CSV del ICFES, GeoJSON de la SED y CSV del MEN). La tabla de hechos quedó con 361.719 resultados del Saber 11 de 2016 a 2022, una vez quitados 162.203 registros duplicados, y la suma del puntaje global coincide con la fuente (99.459.431).

La carga también se concilió con los boletines estadísticos de la SED: para los colegios distritales el puntaje promedio del almacén difiere en 2,5 a 3,4 puntos del publicado. El tablero en Power BI se conecta al almacén y responde las preguntas P0, P1, P2 y P4. Respuesta a la pregunta principal (P0): la brecha entre colegios no oficiales y oficiales pasó de 23,1 puntos en 2016-2019 a 30,7 en 2022, y donde más creció fue en Rafael Uribe Uribe, que pasó de 8,2 a 22,2 puntos (+14,0), seguida de Tunjuelito (+12,3) y Teusaquillo (+11,1).

1. Modelo físico

1.1 Motor y base de datos

El almacén usa MySQL 8.4.11 administrado en la nube (Aiven, plan gratuito), en la base de datos dw. No se usó capa de staging: Pentaho lee los archivos originales y escribe directamente en las tablas del almacén, así que hay un solo esquema (dw). Se eligió una base en la nube para que los tres integrantes y el tablero usen la misma fuente. Los parámetros de conexión, sin contraseñas, están en etl/README.md.

1.2 Tablas creadas

Tabla	Tipo	Llave primaria	Llaves foráneas	Registros	Script DDL
dim_tiempo	Dimensión	sk_tiempo	—	14	dw/ddl/01_dim_tiempo.sql
dim_colegio	Dimensión	sk_sede	—	1.324 (1.323 sedes y la fila −1 Sin dato)	dw/ddl/02_dim_colegio.sql
dim_contexto_colegio_anio	Dimensión	sk_contexto	—	14.678 (14.677 y la fila −1)	dw/ddl/03_dim_contexto_colegio_anio.sql
dim_perfil_estudiante	Dimensión	sk_perfil	—	6.633 (6.632 y la fila −1)	dw/ddl/04_dim_perfil_estudiante.sql
fact_resultado_saber11	Hechos	sk_resultado	sk_tiempo, sk_sede, sk_contexto, sk_perfil	361.719	dw/ddl/05_fact_resultado_saber11.sql

Las llaves de las dimensiones son subrogadas y se generan en la carga; las llaves de la fuente se conservan como atributos con restricción UNIQUE: cod_dane_sede en dim_colegio, la pareja cod_dane_establecimiento y anio en dim_contexto_colegio_anio, y la combinación de las seis condiciones del hogar en dim_perfil_estudiante. La tabla de hechos guarda estu_consecutivo como dimensión degenerada, con una restricción UNIQUE (estu_consecutivo, sk_tiempo) que impide cargar dos veces el mismo resultado. Sus métricas son las de la granularidad definida en la Entrega 1 (un resultado de un estudiante en una aplicación): punt_global, los cinco puntajes por área y cantidad_estudiantes.

El sector y la clase de cada sede se toman del directorio de la SED (corte 30/09/2026) para que ambos atributos sean coherentes; si la sede no está en el directorio, se usa el sector reportado por el ICFES.

1.3 Diagrama del modelo físico

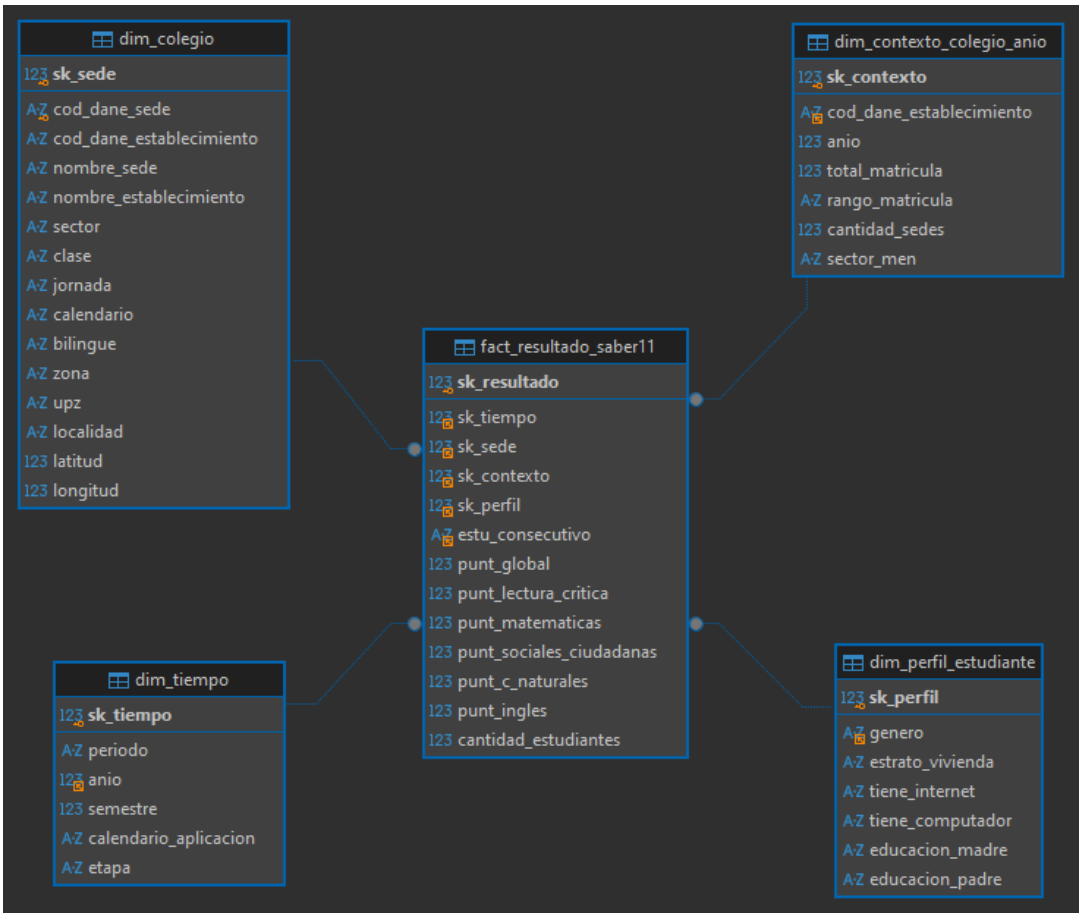


Figura 1. Modelo físico generado con la vista ER de DBeaver sobre la base dw (PNG en /docs/diagramas).

El esquema implementado es en estrella: la tabla de hechos está en el centro y cada una de las cuatro dimensiones se une a ella con una sola llave foránea, sin tablas intermedias entre dimensiones. Coincide con los scripts de dw/ddl y con el esquema diseñado en la Entrega 1.

1.4 Dimensión de tiempo

dim_tiempo cubre los 14 semestres de 2016-1 a 2022-2, sin huecos. Se pobló con la transformación etl/transformaciones/t_dim_tiempo.ktr, la primera que ejecuta el trabajo: define_semestres (Data grid) genera los 14 semestres y calcula_atributos_tiempo (User Defined Java Expression) calcula la llave, el periodo, el calendario y la etapa. Tiene 14 registros y los atributos de su jerarquía periodo → semestre → año → etapa: periodo (por ejemplo, 2019-2), anio, semestre, calendario_aplicacion (B en el primer semestre y A en el segundo) y etapa (prepandemia de 2016 a 2019, pandemia en 2020 y 2021, y pospandemia en 2022).

Periodos faltantes: El ICFES no publicó resultados de 2018-2, 2020-2 y 2021-2. Esos periodos no se inventan ni se rellenan: están en dim_tiempo para que el calendario sea continuo y las comparaciones por etapa tengan todos sus semestres, pero no tienen hechos asociados. Los hechos cubren 11 de los 14 semestres, y la consulta dw/conciliacion/02_hechos_por_periodo.sql los muestra en cero. Además, el ICFES cambió el código del segundo semestre (20172 hasta 2017 y 20194 desde 2019); la transformación de hechos lo convierte a año y semestre en el paso normaliza_periodo.

2. Procesos ETL

2.1 Trabajo de carga

El trabajo etl/trabajos/job_carga_dw.kjb ejecuta la carga completa en este orden: borra_tablas → crea_dim_tiempo → crea_dim_colegio → crea_dim_contexto → crea_dim_perfil → crea_fact → t_dim_tiempo → t_dim_contexto → t_dim_perfil → t_dim_colegio → t_fact_resultado_saber11. Primero recrea las tablas y carga las cuatro dimensiones; al final carga los hechos, que buscan sus llaves en las dimensiones. Al ser una carga completa, se puede repetir sobre la base sin duplicar datos.



Figura 2. Trabajo job_carga_dw.kjb en Spoon después de la ejecución completa: todas las entradas terminaron con éxito. Fuente: elaboración propia.

2.2 Transformaciones

Archivo .ktr	Fuente(s) y formato	Destino	Pasos principales	Leídos	Escritos	Rechazos
t_dim_tiempo.ktr	Sin fuente: calendario generado en PDI	dim_tiempo	Data grid (define_semestres) → User Defined Java Expression (calcula_atributos_tiempo) → Table output	14	14	0
t_dim_ contexto.ktr	F3 MEN (CSV)	dim_contexto_ colegio_anio	CSV file input → Filter rows (filtra_bogota, filtra_anios, filtra_caracter_guion) → Replace in string → Select values → Formula → Unique rows → Table output	606.206	14.677	591.529 filtradas
t_dim_perfil.ktr	F1 ICFES (CSV)	dim_perfil_ estudiante	CSV file input → Select values → Formula → Filter rows → Formula → Sort rows (únicos) → Table output	523.922	6.632	0
t_dim_colegio.ktr	F1 ICFES (CSV) y F2 SED (GeoJSON)	dim_colegio	CSV file input y JSON input → Filter rows → Replace in string → Sort rows → Unique rows → Value mapper → User Defined Java Expression → Stream lookup → Formula → Table output	523.922 (F1) y 2.176 (F2)	1.323	0
t_fact_resultado_ saber11.ktr	F1 ICFES (CSV)	fact_resultado_ saber11	CSV file input → Select values → Sort rows (únicos) → Formula → Filter rows → Database lookup ×4 → Table output	523.922	361.719	162.203 duplicados

Las dimensiones de perfil y colegio no descartan filas: resumen las 523.922 filas de F1 en 6.632 combinaciones de perfil y 1.323 sedes. La transformación de hechos busca cada llave con un paso Database lookup (busca_sk_tiempo, busca_sk_colegio, busca_sk_contexto y busca_sk_perfil); si no encuentra pareja, el resultado apunta a la fila −1 Sin dato de la dimensión en lugar de perderse. En la carga, 634 resultados (28 combinaciones de establecimiento y año que no están en F3) quedaron con contexto −1; ninguno quedó sin tiempo, colegio ni perfil.

2.3 Reglas de limpieza aplicadas

Problema (Entrega 1)	Fuente y campo	Regla aplicada	Paso de PDI (nombre)	Registros afectados
Registros duplicados	F1, todas las filas	Conservar una fila por estudiante y periodo (ESTU_CONSECUTIVO + PERIODO); los duplicados son idénticos	quita_duplicados (Sort rows, solo filas únicas)	162.203 filas quitadas
El código del periodo cambia y faltan periodos	F1.PERIODO	Convertir el código a año y semestre: el último dígito 1 es semestre 1, y 2 o 4 es semestre 2. Los periodos faltantes no se rellenan	normaliza_periodo (Formula), filtra_periodo_ recodificado (Filter rows) y cuenta_periodo_ recodificado	159.085 filas con el código terminado en 4
Departamento escrito de dos formas	F1.COLE_DEPTO_ UBICACION	Unificar «BOGOTÁ» y «BOGOTA» en «BOGOTA»	filtra_depto_con_tilde (Filter rows) y unifica_ bogota (Replace in string)	330.259 filas
Sistema de coordenadas distinto al documentado	F2, geometría	Convertir de EPSG 3857 (metros) a latitud y longitud en grados (EPSG 4326)	convierte_coordenadas (User Defined Java Expression)	2.176 sedes
Campos codificados y diccionarios contradictorios	F2.SECTOR, CLASE_ TIPO, CALENDARIO, ZONA, COD_LOCA y NATU_JUR	Traducir los códigos a texto con el dominio del servicio REST de la SED; NATU_JUR no se lee porque el modelo no la usa	traduce_sector, traduce_ clase, traduce_calendario, traduce_zona y traduce_ localidad (Value mapper); lee_f2_json (JSON input)	2.176 sedes por campo; 2 sedes con NATU_JUR 19
Archivo y servicio con distinta cobertura y fecha de corte	F2, archivo frente a servicio REST	Leer solo el archivo GeoJSON (corte 30/09/2026); el servicio REST (2.211 sedes, corte 31/12/2025) solo se usó para los dominios	lee_f2_json (JSON input)	2.176 sedes leídas
Números con punto de miles	F3.AÑO, CODIGO_ DANE, TOTAL_ MATRICULA y CANTIDAD_SEDES	Quitar el punto de miles antes de convertir a número	quita_puntos_miles (Replace in string)	22.512 filas de Bogotá
Volumen anómalo del año 2023	F3.AÑO	Conservar solo los años 2016 a 2022, que son los de los hechos	filtra_anios (Filter rows) y descarta_fuera_periodo	7.835 filas descartadas
Valores vacíos representados con guion	F3.CARACTER	Separar y contar los registros con «-»; la columna no pasa al almacén porque el modelo no la usa	filtra_caracter_guion (Filter rows), cuenta_caracter_ guion y selecciona_ columnas (Select values)	881 de 14.677 filas

2.4 Evidencia de ejecución

La ejecución completa del trabajo del 06/11/2026 duró 11 minutos (19:13:42 a 19:24:20) y terminó sin errores: todas las entradas aparecen con resultado Success (Figura 3). Las Figuras 4 a 8 muestran la pestaña de métricas de pasos de cada transformación, en el orden del trabajo: todos los pasos terminaron (Finished) con 0 errores, y las filas leídas y escritas son las de la tabla 2.2.

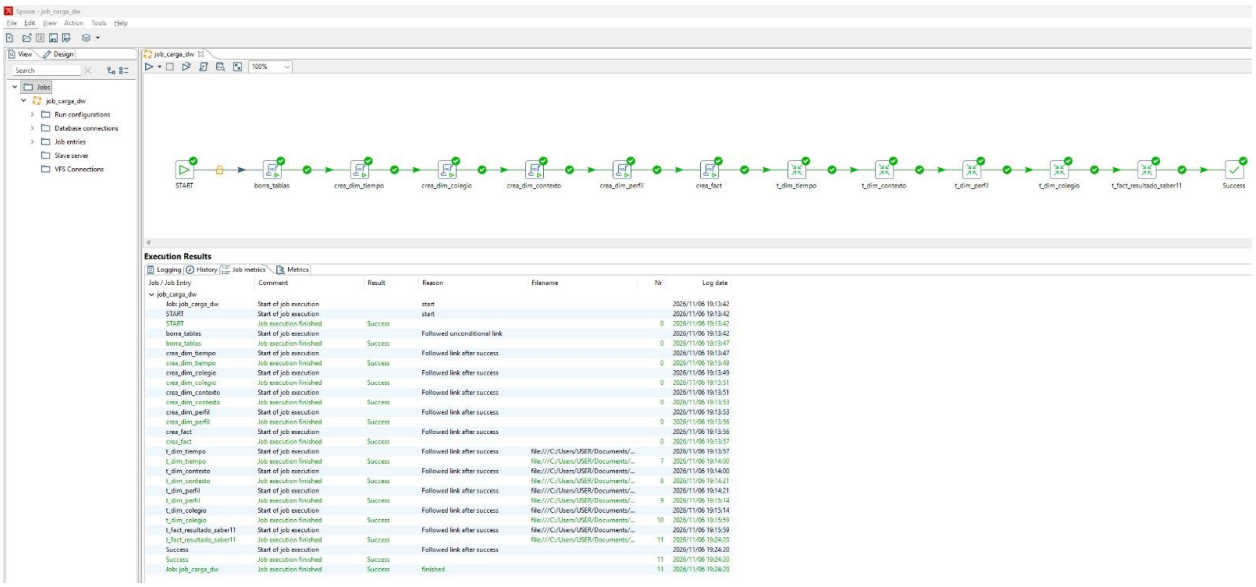


Figura 3. Pestaña Job metrics de la ejecución completa del trabajo.

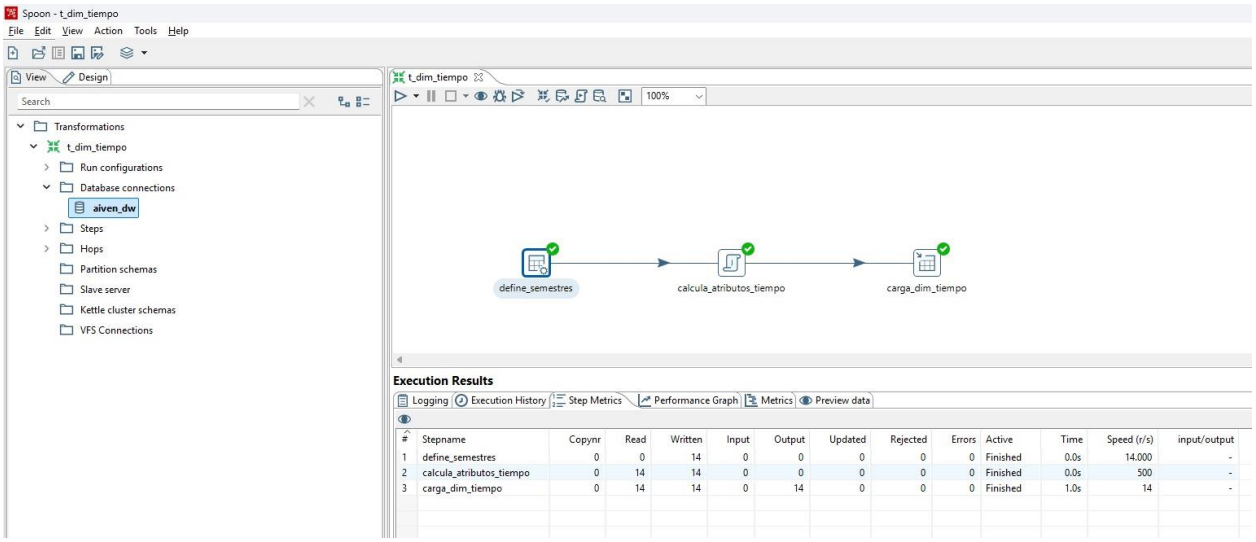


Figura 4. Métricas de pasos de t_dim_tiempo.ktr: 14 semestres generados y cargados, sin errores.

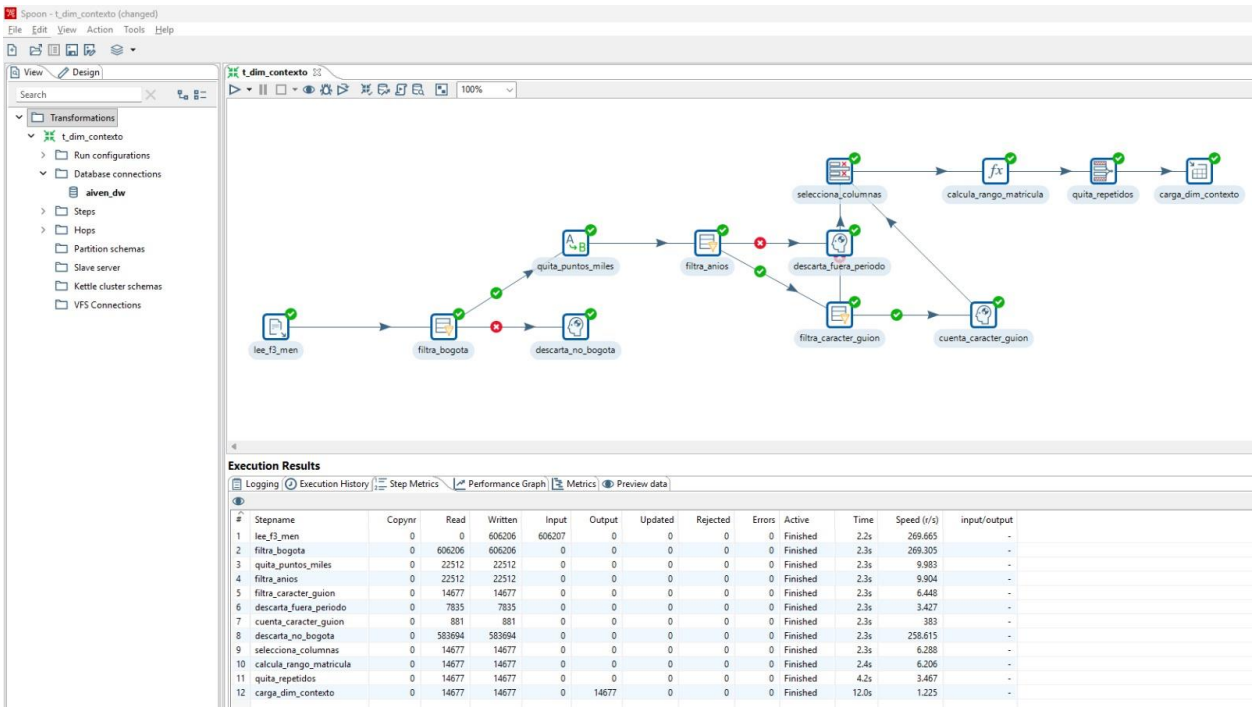


Figura 5. Métricas de pasos de t_dim_contexto.ktr: 606.206 filas leídas de F3 y 14.677 cargadas, sin errores.

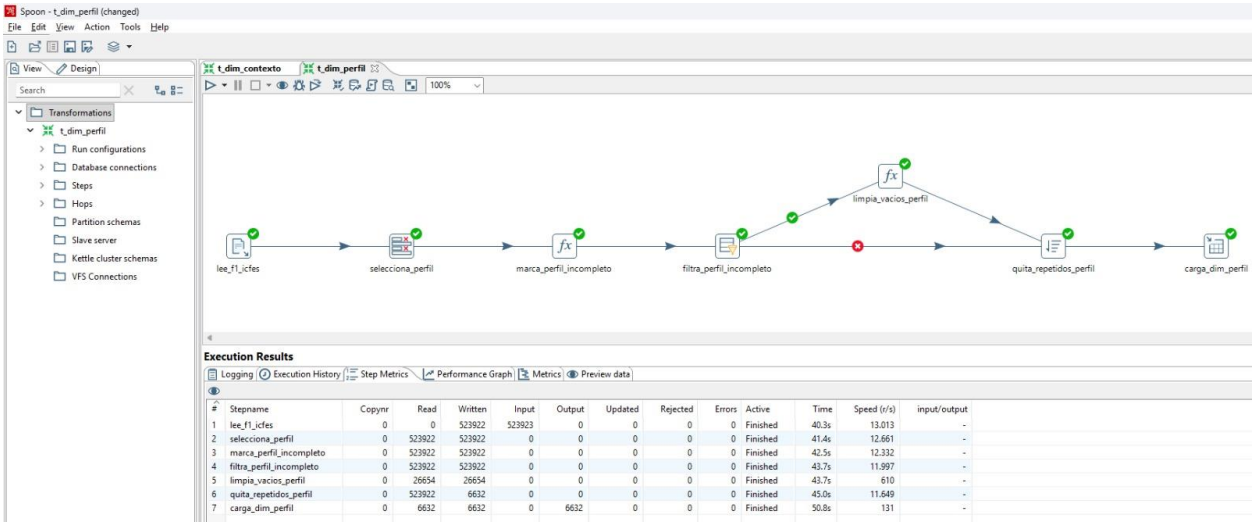


Figura 6. Métricas de pasos de t_dim_perfil.ktr: 523.922 filas leídas de F1 y 6.632 combinaciones cargadas, sin errores.

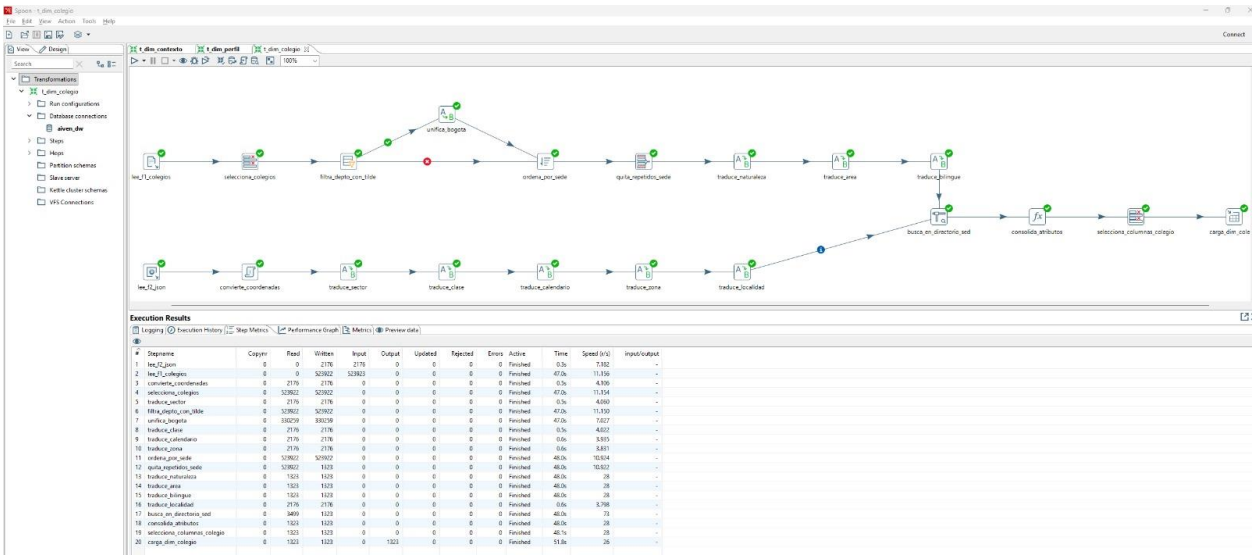


Figura 7. Métricas de pasos de t_dim_colegio.ktr: 523.922 filas de F1 y 2.176 de F2 leídas, 1.323 sedes cargadas, sin errores.

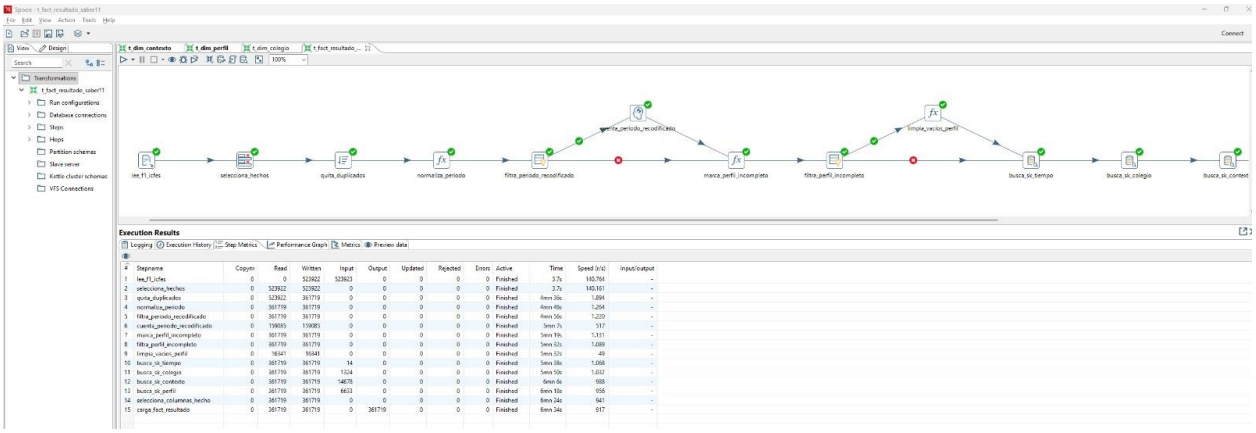


Figura 8. Métricas de pasos de t_fact_resultado_saber11.ktr: 523.922 filas leídas y 361.719 resultados cargados, sin errores.

3. Conciliación

3.1 Conteo por fuente

Las cifras salen de las métricas de PDI y de las consultas de /dw/conciliacion (Anexo A). En las tres fuentes se cumple que los registros leídos son iguales a los cargados más los descartados.

Fuente	Leídos	Cargados	Descartados	Motivo de los descartes
F1 ICFES	523.922	361.719	162.203	Resultados duplicados, idénticos, de un mismo estudiante en un mismo periodo (159.417 en 2019 y 2022).
F2 SED	2.176	1.171	1.005	Sedes del directorio sin resultados del Saber 11 en F1: no tienen hechos. Las 1.171 restantes enriquecen dim_colegio.
F3 MEN	606.206	14.677	591.529	583.694 filas de establecimientos fuera de Bogotá y 7.835 de años fuera de 2016-2022.

Diferencias explicadas: dim_colegio tiene 1.323 sedes porque 152 sedes de F1 no están en el directorio de la SED y se cargan con sus datos del ICFES y la localidad «Sin dato». Los 634 resultados con contexto −1 sí están en la tabla de hechos: solo les falta la matrícula del MEN de ese año.

3.2 Totales de una métrica

Se comparan los totales de las métricas de F1 (sin duplicados) con la tabla de hechos y los de F3 (Bogotá, 2016 a 2022) con dim_contexto_colegio_anio. F2 es un directorio de sedes sin métricas que sumar, así que se concilia solo por conteo (sección 3.1).

Métrica	Total en la fuente	Total en el DW	Diferencia y explicación
F1 · suma de punt_global	99.459.431	99.459.431	0. Coinciden.
F1 · suma de cantidad_estudiantes	361.719	361.719	0. Un registro por resultado único.
F3 · suma de total_matricula	9.111.294	9.111.294	0. Coinciden.
F3 · suma de cantidad_sedes	17.026	17.026	0. Coinciden.

Las consultas 03_totales_metricas.sql y 07_totales_f3.sql dan estos totales. La consulta 02_hechos_por_periodo.sql repite la comparación por periodo: en los 11 periodos con datos, el número de resultados y la suma de punt_global coinciden con F1 sin duplicados, y los periodos 2018-2, 2020-2 y 2021-2 aparecen sin hechos. La consulta 05_brecha_por_sector.sql confirma que el almacén reproduce la brecha calculada en la Entrega 1 entre colegios no oficiales y oficiales: 24,9 puntos en 2019 y 30,7 en 2022.

Comparación con los boletines estadísticos de la SED: Además de la fuente, el puntaje promedio y el número de evaluados del almacén se compararon con las cifras oficiales de la SED para el calendario A de 2019 (boletín 2019, Tabla 89) y de 2022 (boletín 2022, Tabla 95). Como el boletín reporta colegios distritales y privados, el almacén se agrupa por la clase de colegio del directorio de la SED (consulta dw/conciliacion/06_boletines_sed.sql).

Año y clase	Boletín SED	Almacén	Diferencia
2019 · Distrital	39.650 evaluados · 257,1	43.300 evaluados · 253,7	+3.650 evaluados · −3,4 puntos
2019 · Privado	33.645 evaluados · 290,3	33.055 evaluados · 281,3	−590 evaluados · −9,0 puntos
2022 · Distrital	38.062 evaluados · 258,5	40.898 evaluados · 256,0	+2.836 evaluados · −2,5 puntos
2022 · Privado	30.400 evaluados · 297,0	30.174 evaluados · 288,8	−226 evaluados · −8,2 puntos

Explicación de las diferencias: El número de evaluados de los colegios privados coincide en más del 98 %. En los distritales el almacén tiene entre 7 % y 9 % más evaluados, con un promedio 2,5 a 3,4 puntos menor, y en los privados el boletín reporta un promedio 8 a 9 puntos mayor. Las causas identificadas son tres: el boletín de 2022 advierte que usa datos provisionales de la primera publicación del ICFES, mientras que F1 es la versión publicada en datos abiertos; la clase de cada colegio en el almacén es la del directorio vigente de la SED (corte 30/09/2026) y no la que tenía el año del examen; y el boletín clasifica a los colegios con criterios propios (en 2022 sus filas de distritales y privados suman 68.462 de un total de 73.045 evaluados). Con la información publicada no es posible atribuir a cada causa una parte exacta de la diferencia, pero ninguna proviene de la carga: la conciliación con la fuente cuadra sin diferencias.

4. Tablero

4.1 Indicadores

Las medidas están en el archivo dashboard/tablero_saber11.pbix, que se conecta a la base dw de MySQL en Aiven. Las comparaciones entre etapas usan el segundo semestre (calendario A), igual que la Entrega 1.

Indicador	Fórmula (DAX o SQL)	Qué mide	Referencia	Pregunta
Brecha 2022	Brecha 2022 = CALCULATE([Brecha], REMOVEFILTERS(dim_tiempo), dim_tiempo[anio] = 2022, dim_tiempo[semestre] = 2), donde Brecha = [Promedio no oficial] − [Promedio oficial]	Diferencia de puntaje global promedio entre colegios no oficiales y oficiales en 2022	Brecha prepandemia 2016-2019 (periodo anterior): 23,14 → 30,68 puntos; cambio de +7,54	P0
% de colegios oficiales sin recuperar	% sin recuperar = DIVIDE([Colegios oficiales sin recuperar], [Colegios oficiales comparables]); un colegio no recupera si [Prom 2022] − [Prom 2016-2019] < 0	Proporción de colegios oficiales con datos en ambos periodos cuyo puntaje de 2022 quedó por debajo de su promedio 2016-2019	Promedio 2016-2019 de cada colegio (periodo anterior): 273 de 365 colegios, 74,79 %	P1
Diferencia con y sin internet	Diferencia con y sin internet = [Promedio con internet] − [Promedio sin internet], con CALCULATE([Puntaje promedio], dim_perfil_estudiante[tiene_internet] = "Si") y = "No"	Ventaja en puntaje global de los estudiantes con internet en el hogar sobre los que no tienen	Etapa prepandemia (periodo anterior): 23,2 → 31,2 puntos en pospandemia	P2

Fórmulas completas de las medidas (archivo dashboard/tablero_saber11.pbix):

```
Puntaje promedio = AVERAGE(fact_resultado_saber11[punt_global])
Promedio oficial = CALCULATE([Puntaje promedio], dim_colegio[sector] = "Oficial")
Promedio no oficial = CALCULATE([Puntaje promedio], dim_colegio[sector] = "No oficial")
Brecha = IF(ISBLANK([Promedio oficial]) || ISBLANK([Promedio no oficial]), BLANK(),
    [Promedio no oficial] - [Promedio oficial])
Brecha prepandemia = CALCULATE([Brecha], REMOVEFILTERS(dim_tiempo),
    dim_tiempo[etapa] = "prepandemia", dim_tiempo[semestre] = 2)
Brecha 2022 = CALCULATE([Brecha], REMOVEFILTERS(dim_tiempo),
    dim_tiempo[anio] = 2022, dim_tiempo[semestre] = 2)
Cambio de brecha = [Brecha 2022] - [Brecha prepandemia]
Prom 2016-2019 = CALCULATE([Puntaje promedio], REMOVEFILTERS(dim_tiempo),
    dim_tiempo[etapa] = "prepandemia", dim_tiempo[semestre] = 2)
Prom 2022 = CALCULATE([Puntaje promedio], REMOVEFILTERS(dim_tiempo),
    dim_tiempo[anio] = 2022, dim_tiempo[semestre] = 2)
Variación vs 2016-2019 = IF(ISBLANK([Prom 2022]) || ISBLANK([Prom 2016-2019]), BLANK(),
    [Prom 2022] - [Prom 2016-2019])
Colegios oficiales comparables = CALCULATE(
    COUNTROWS(FILTER(VALUES(dim_colegio[cod_dane_establecimiento]),
        NOT ISBLANK([Prom 2022]) && NOT ISBLANK([Prom 2016-2019]))),
    dim_colegio[sector] = "Oficial")
Colegios oficiales sin recuperar = CALCULATE(
    COUNTROWS(FILTER(VALUES(dim_colegio[cod_dane_establecimiento]),
        NOT ISBLANK([Prom 2022]) && NOT ISBLANK([Prom 2016-2019])
        && [Variación vs 2016-2019] < 0)),
    dim_colegio[sector] = "Oficial")
% sin recuperar = DIVIDE([Colegios oficiales sin recuperar], [Colegios oficiales comparables])
Promedio con internet = CALCULATE([Puntaje promedio], dim_perfil_estudiante[tiene_internet] = "Si")
Promedio sin internet = CALCULATE([Puntaje promedio], dim_perfil_estudiante[tiene_internet] = "No")
Diferencia con y sin internet = IF(ISBLANK([Promedio con internet]) || ISBLANK([Promedio sin internet]),
    BLANK(), [Promedio con internet] - [Promedio sin internet])
Matrícula promedio = AVERAGEX(fact_resultado_saber11, RELATED(dim_contexto_colegio_anio[total_matricula]))
```

4.2 Respuesta a las preguntas de negocio

Las preguntas de tipo BI de la tabla 1.3 de la Entrega 1 son P0, P1, P2 y P4; P3 es de tipo BA y se responde con el modelo predictivo.

Pregunta	Página y visual	Tipo de gráfico y por qué	Respuesta encontrada (con cifra)
P0	Página «P0 Brecha por localidad»: barras del cambio de la brecha por localidad y tarjetas de la brecha	Barras horizontales ordenadas: comparan las 19 localidades con datos, que son categorías sin orden, y dejan arriba las que más crecieron	La brecha de Bogotá pasó de 23,1 a 30,7 puntos (+7,5). Más creció en Rafael Uribe Uribe, de 8,2 a 22,2 puntos (+14,0), seguida de Tunjuelito (+12,3) y Teusaquillo (+11,1); se redujo en Chapinero (−15,3), Santa Fe (−9,1) y Usaquén (−4,1). Sumapaz no aparece porque solo tiene colegios oficiales y no hay brecha que calcular
P1	Página «P1 Colegios sin recuperación»: tabla de colegios oficiales, tarjetas y barras del % por localidad	Tabla: la pregunta pide los colegios con nombre, ordenados por su caída; barras para comparar el porcentaje entre localidades	273 de 365 colegios oficiales (74,8 %) no recuperaron su puntaje. Las mayores caídas: Colegio Santa Martha, Usme (−25,2), Guillermo León Valencia, Engativá (−23,3) y Los Pinos, Santa Fe (−22,8)
P2	Página «P2 Internet en el hogar»: columnas del puntaje por etapa y acceso a internet, y columnas de la diferencia	Columnas agrupadas: comparan pocas categorías (dos etapas y tres grupos de acceso)	La diferencia entre estudiantes con y sin internet pasó de 23,2 puntos antes de la pandemia a 31,2 después (+8,0)
P4	Página «P4 Tamaño y puntaje»: dispersión de matrícula y puntaje promedio por colegio, coloreada por sector	Dispersión: muestra la relación entre dos variables numéricas, con un punto por colegio	No hay una relación clara entre tamaño y puntaje dentro de cada sector: los no oficiales tienen en su mayoría menos de 1.000 estudiantes y puntajes de 220 a 370; los oficiales tienen de 1.000 a 4.000 estudiantes y puntajes de 230 a 290

4.3 Capturas del tablero

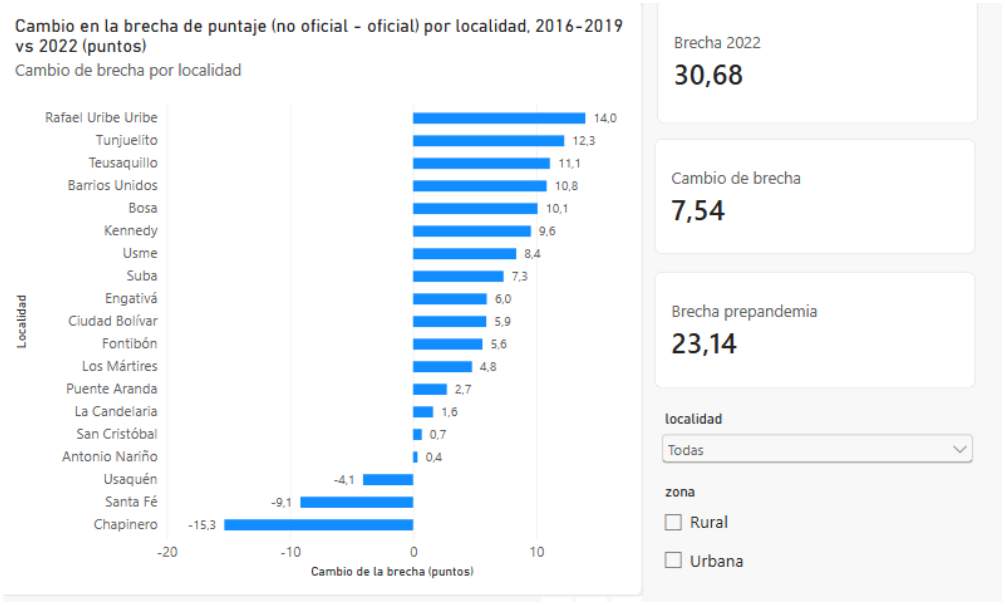


Figura 9. Página P0 Brecha por localidad del tablero.

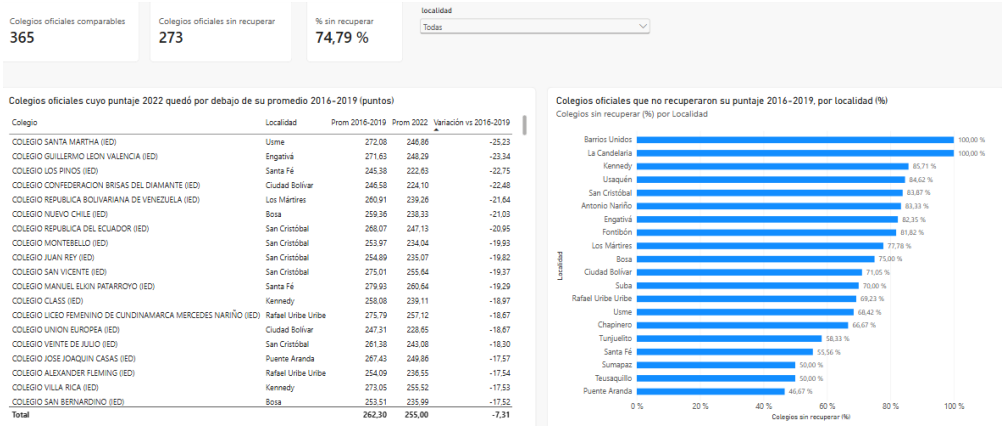


Figura 10. Página P1 Colegios sin recuperación del tablero.

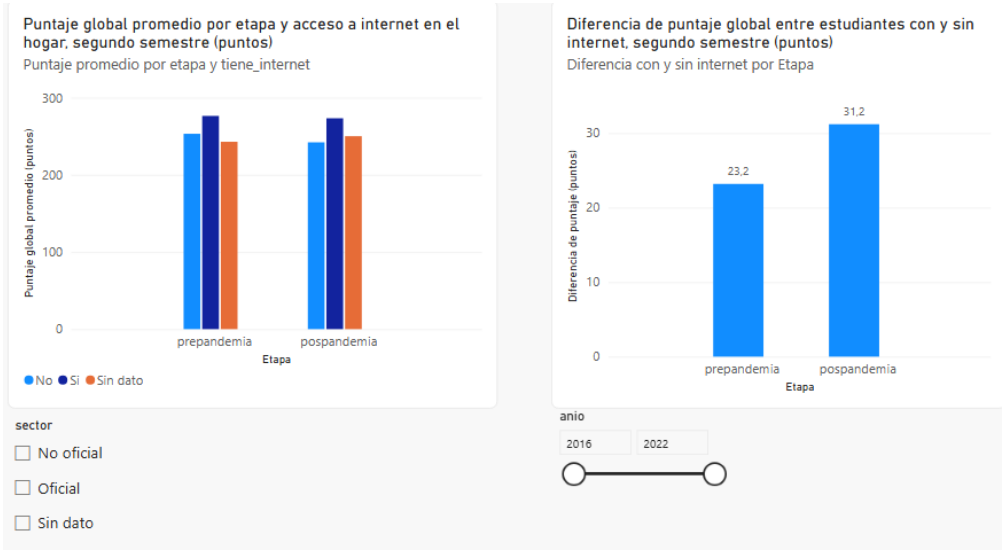


Figura 11. Página P2 Internet en el hogar del tablero.

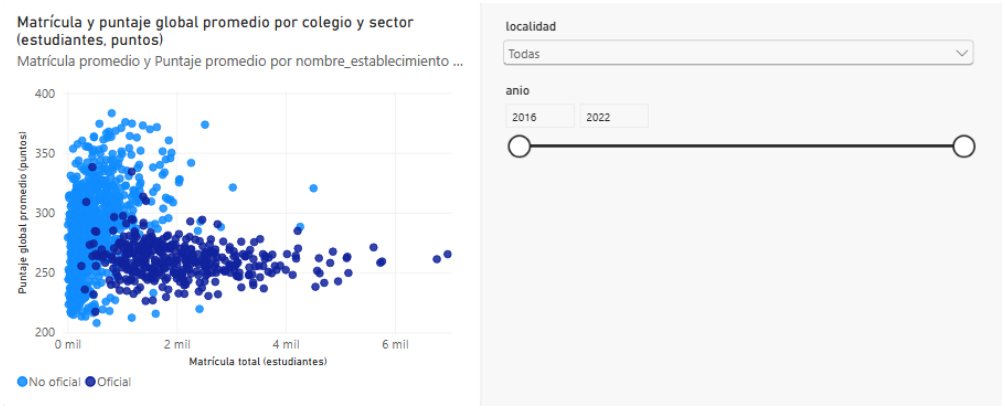


Figura 12. Página P4 Tamaño y puntaje del tablero.

4.4 Filtros

Cada página tiene segmentadores que filtran todos sus visuales:

• **P0 Brecha por localidad:** localidad (menú desplegable) y zona (rural o urbana).

- **P1 Colegios sin recuperación:** localidad (menú desplegable).
- **P2 Internet en el hogar:** año (2016 a 2022) y sector.
- **P4 Tamaño y puntaje:** año (2016 a 2022) y localidad (menú desplegable).

Las páginas P2 y P4 combinan un filtro de tiempo con otra dimensión. En P0 y P1 las medidas comparan siempre 2016-2019 con 2022, por eso esas páginas filtran por localidad y zona, y no por año.

Anexos

Anexo A. Consultas de conciliación

Consultas de /dw/conciliacion ejecutadas sobre la base dw.

01_conteo_por_tabla.sql

```
-- Conciliacion 1: registros cargados en cada tabla del almacen (se comparan con las metricas de PDI)
-- Esperado: dim_tiempo 14, dim_colegio 1324, dim_contexto_colegio_anio 14678,
--           dim_perfil_estudiante 6633, fact_resultado_saber11 361719
-- Cada dimension incluye ademas la fila -1 Sin dato (dim_tiempo no la tiene)
SELECT 'dim_tiempo' AS tabla, COUNT(*) AS registros FROM dim_tiempo
UNION ALL SELECT 'dim_colegio', COUNT(*) FROM dim_colegio
UNION ALL SELECT 'dim_contexto_colegio_anio', COUNT(*) FROM dim_contexto_colegio_anio
UNION ALL SELECT 'dim_perfil_estudiante', COUNT(*) FROM dim_perfil_estudiante
UNION ALL SELECT 'fact_resultado_saber11', COUNT(*) FROM fact_resultado_saber11;
```

02_hechos_por_periodo.sql

```
-- Conciliacion 2: hechos y suma de punt_global por periodo, contra la fuente F1 sin duplicados
-- Esperado (resultados, suma de punt_global):
--   2016-1: 2596, 952379      2016-2: 89900, 24908243   2017-1: 2530, 884358    2017-2: 88426, 24195374
--   2018-1: 4979, 1487330     2019-1: 2446, 856481      2019-2: 82832, 22017091  2020-1: 3610, 1071621
--   2021-1: 3259, 1057151     2022-1: 4888, 1422343     2022-2: 76253, 20607060
-- Los periodos 2018-2, 2020-2 y 2021-2 no se publicaron: aparecen sin hechos (LEFT JOIN)
SELECT t.periodo, COUNT(f.sk_resultado) AS resultados, SUM(f.punt_global) AS suma_punt_global
FROM dim_tiempo t
LEFT JOIN fact_resultado_saber11 f ON f.sk_tiempo = t.sk_tiempo
GROUP BY t.sk_tiempo, t.periodo
ORDER BY t.sk_tiempo;
```

03_totales_metricas.sql

```
-- Conciliacion 3: total de cada metrica de la tabla de hechos en el almacen
-- Fuente: F1 sin duplicados (361.719 resultados). Esperado:
--   punt_global 99459431, punt_lectura_critica 20432435, punt_matematicas 19983520,
--   punt_sociales_ciudadanas 19290581, punt_c_naturales 19685933, punt_ingles 20414297
--   (punt_ingles tiene 39 resultados vacios), cantidad_estudiantes 361719
SELECT COUNT(*) AS resultados,
       SUM(punt_global) AS suma_punt_global,
       SUM(punt_lectura_critica) AS suma_lectura_critica,
       SUM(punt_matematicas) AS suma_matematicas,
       SUM(punt_sociales_ciudadanas) AS suma_sociales_ciudadanas,
       SUM(punt_c_naturales) AS suma_c_naturales,
       SUM(punt_ingles) AS suma_ingles,
       COUNT(punt_ingles) AS ingles_con_dato,
       SUM(cantidad_estudiantes) AS suma_cantidad_estudiantes
FROM fact_resultado_saber11;
```

04_hechos_sin_pareja.sql

```
-- Conciliacion 4: hechos que apuntan al miembro -1 Sin dato de cada dimension
-- Esperado: sin tiempo 0, sin colegio 0, sin contexto del MEN 634, sin perfil 0
-- Los 634 corresponden a 28 combinaciones establecimiento-anio que no estan en F3
SELECT COUNT(*) AS resultados,
       SUM(sk_tiempo = -1) AS sin_tiempo,
       SUM(sk_sede = -1) AS sin_colegio,
       SUM(sk_contexto = -1) AS sin_contexto,
       SUM(sk_perfil = -1) AS sin_perfil
FROM fact_resultado_saber11;


-- Sedes del almacen que no estan en el directorio de la SED (F2): esperado 152 sedes
SELECT COUNT(*) AS sedes_sin_directorio
FROM dim_colegio
WHERE sk_sede <> -1 AND localidad = 'Sin dato';

-- Resultados de esas sedes: esperado 18903 (3,6 % de 523922 filas de F1 con duplicados)
-- En el almacen, sin duplicados, el numero es menor
SELECT COUNT(*) AS resultados_sedes_sin_directorio
FROM fact_resultado_saber11 f
JOIN dim_colegio c ON c.sk_sede = f.sk_sede
```

```
WHERE c.localidad = 'Sin dato';
```

05_brecha_por_sector.sql

```
-- Conciliacion 5: puntaje global promedio por sector en el segundo semestre (calendario A)
-- Se compara con las cifras de la Entrega 1 (calculo propio con datos del ICFES):
-- la brecha entre no oficiales y oficiales pasa de 24,9 puntos en 2019 a 30,7 en 2022.
-- Esperado desde la fuente: 2016 22,8; 2017 22,0; 2019 24,9; 2022 30,7
SELECT t.anio,
       ROUND(AVG(CASE WHEN c.sector = 'Oficial' THEN f.punt_global END), 1) AS promedio_oficial,
       ROUND(AVG(CASE WHEN c.sector = 'No oficial' THEN f.punt_global END), 1) AS promedio_no_oficial,
       ROUND(AVG(CASE WHEN c.sector = 'No oficial' THEN f.punt_global END)
           - AVG(CASE WHEN c.sector = 'Oficial' THEN f.punt_global END), 1) AS brecha
FROM fact_resultado_saber11 f
JOIN dim_tiempo t ON t.sk_tiempo = f.sk_tiempo
JOIN dim_colegio c ON c.sk_sede = f.sk_sede
WHERE t.semestre = 2
GROUP BY t.anio
ORDER BY t.anio;
```

06_boletines_sed.sql

```
-- Conciliacion 6: comparacion con los boletines estadisticos de la SED (Saber 11, calendario A)
-- Se agrupa por clase de colegio del directorio de la SED, porque el boletin reporta colegios distritales y
privados
-- Boletin 2019, Tabla 89: colegios oficiales (IED) 39.650 evaluados y 257,1; privados 33.645 y 290,3
-- Boletin 2022, Tabla 95 (datos provisionales): distritales 38.062 y 258,52; privados 30.400 y 296,95
-- Resultado en el almacen: 2019-2 Distrital 43.300 y 253,7; Privado 33.055 y 281,3
--                          2022-2 Distrital 40.898 y 256,0; Privado 30.174 y 288,8
SELECT t.periodo,
       c.clase,
       COUNT(*)                    AS evaluados,
       ROUND(AVG(f.punt_global), 1) AS promedio_global
FROM fact_resultado_saber11 f
JOIN dim_tiempo  t ON t.sk_tiempo = f.sk_tiempo
JOIN dim_colegio c ON c.sk_sede   = f.sk_sede
WHERE t.periodo IN ('2019-2', '2022-2')
GROUP BY t.periodo, c.clase
ORDER BY t.periodo, c.clase;
```

07_totales_f3.sql

```
-- Conciliacion 7: totales de las metricas de F3 (MEN) en dim_contexto_colegio_anio
-- Esperado desde la fuente: F3, Bogota, anios 2016 a 2022 (14677 filas)
--   total_matricula 9111294, cantidad_sedes 17026
-- F2 (directorio de la SED) no tiene metricas que sumar: se concilia solo por conteo (01_conteo_por_tabla.sql)
SELECT SUM(total_matricula) AS total_matricula,
       SUM(cantidad_sedes)  AS cantidad_sedes,
       COUNT(*)             AS filas
FROM dim_contexto_colegio_anio
WHERE sk_contexto <> -1;
```

Anexo B. Capturas adicionales

Las capturas de las cinco transformaciones en PDI, con sus métricas de pasos, están en la sección 2.4 (Figuras 4 a 8). El tablero tiene cuatro páginas y todas están en la sección 4.3 (Figuras 9 a 12).